

# Συγκριτική Ανάλυση Αναπαράστασης Γραφημάτων ως Διανύσματα για Μοντέλα Μηχανικής Μάθησης

Γρατούσα Μαρία  
el20082

Μητρόπουλος Σταύρος  
el20847

Τζανέτος Δημήτριος  
el19871

**Abstract**—Η αναπαράσταση γραφημάτων σε διανύσματα (**graph embeddings**) αποτελεί βασικό εργαλείο για την επίλυση προβλημάτων ταξινόμησης γράφων. Στην παρούσα εργασία, μελετήθηκαν και αξιολογήθηκαν μέθοδοι τέτοιων μετατροπών και αξιολογήθηκαν πάνω σε κλασσικά σύνολα δεδομένων και μοντέλα Μηχανικής Μάθησης.

**Index Terms**—Graph Embeddings, Machine Learning, Classification, Graph Data

## I. Εισαγωγή

Η αναπαράσταση γραφημάτων σε διανύσματα (**graph embeddings**) αποτελεί βασικό εργαλείο για την επίλυση προβλημάτων ταξινόμησης γράφων. Οι σύγχρονες προσεγγίσεις περιλαμβάνουν τόσο μη επιβλεπόμενες μεθόδους, όσο και επιβλεπόμενα μοντέλα βαθιάς μάθησης βασισμένα σε Graph Neural Networks (GNNs).

Σκοπός της παρούσας εργασίας είναι η συγκριτική αξιολόγηση διαφορετικών μεθόδων αναπαράστασης γράφων δεδομένων ως προς την απόδοση και το υπολογιστικό κόστος τους, σε σύνολα δεδομένων με διαφορετικά χαρακτηριστικά.

Η συνεισφορά της εργασίας συνοψίζεται ως εξής:

- Σύγκριση μη επιβλεπόμενων και επιβλεπόμενων μεθόδων **graph embedding**.
- Αξιολόγηση επιδόσεων σε **benchmark datasets**.
- Ανάλυση της σχέσης ακρίβειας των μοντέλων που χρησιμοποιούν τα **graph embeddings** και του υπολογιστικού κόστους παραγωγής των **embeddings**.

Project repo [σύνδεσμος](https://github.com/StavrosMitro/comparative-graph-embedding-analysis).

<https://github.com/StavrosMitro/comparative-graph-embedding-analysis>

## II. Σχετική Βιβλιογραφία

Στην παρούσα εργασία χρησιμοποιήθηκαν οι **unsupervised** μέθοδοι **Family of Graph Spectral Distances** [1], **Graph2Vec** [2] και η **supervised** μέθοδος **GIN** [5].

Στην εργασία για την **FGSD**, οι ερευνητές εισάγουν την οικογένεια αυτή, στοχεύοντας στη διασφάλιση κρίσιμων ιδιοτήτων όπως η μοναδικότητα, η ευστάθεια, η αραιότητα και η υπολογιστική ταχύτητα, χρησιμοποιώντας τις φασματικές αποστάσεις του γραφήματος για την κατασκευή **embeddings** μοντέλων μηχανικής μάθησης.

Το μοντέλο **Graph Isomorphism Networks (GIN)**, όπως παρουσιάστηκε από τους Xu *et al.* [5], σχεδιάστηκε με σκοπό να διαχωρίζει τοπολογίες γραφημάτων με ακρίβεια ίση με αυτή του έλεγχου ισομορφισμού γράφων **Weisfeiler-Lehman (1-WL)** [10].

## III. Σύνολα Δεδομένων

Τα σύνολα δεδομένων **ENZYMES**, **IMDB-MULTI** και **REDDIT-MULTI-12K** είναι αυτά στα οποία θα αξιολογηθούν τα **graph embeddings**. Τα σύνολα αυτά διαφέρουν ως προς το πλήθος των γράφων, το μέγεθος των γράφων, τον διαχωρισμό και το πλήθος των κλάσεων και τα στοιχεία που μας δίνουν πληροφορία για να έχουμε σωστές προβλέψεις. Αυτό μας επιτρέπει να έχουμε καλύτερα συμπεράσματα για την ποιότητα των παραγόμενων **graph embeddings**.

Αναλυτικότερα, τα βασικά χαρακτηριστικά των **datasets**:

- **ENZYMES**: Ένα **dataset** από τον κλάδο της βιοπληροφορικής. Κάθε γράφος αναπαριστά πρωτεϊνικές τριτοταγείς δομές ενζύμων και κάθε κόμβος φέρει διακριτά χαρακτηριστικά (**attributes**) που αντιστοιχούν σε δευτεροταγείς δομές, υπάρχουν τριών ειδών χαρακτηριστικά στους κόμβους των γράφων. Κάθε ένζυμο ταξινομείται σε μία από τις 6 κλάσεις της ονοματολογίας **EC (Enzyme Commission top-level classes)**.
- **IMDB-MULTI**: Social dataset. Κάθε γράφος αντιστοιχεί σε **ego-network** ενός ηθοποιού, όπου οι κόμβοι είναι ηθοποιοί και οι ακμές υποδηλώνουν συνεργασία σε ταινία. Κάθε ταινία ανήκει σε ένα από τα 3 είδη ταινιών: **Drama**, **Comedy**, **Action/Sci-Fi**. Το **dataset** αυτό χαρακτηρίζεται από πυκνές συνδέσεις και απουσία χαρακτηριστικών κόμβων (για **supervised learning** χρησιμοποιήθηκε **one-hot encoding**).
- **REDDIT-MULTI-12K**: Ένα μεγάλης κλίμακας **dataset** από την πλατφόρμα κοινωνικής δικτύωσης **Reddit**. Κάθε γράφος αναπαριστά ένα **discussion thread**, όπου οι κόμβοι είναι χρήστες και οι ακμές απαντήσεις μεταξύ τους. Έχει 11 κλάσεις που αντιστοιχούν σε **subreddit**

(κοινότητες). Το dataset αυτό είναι ιδανικό για τον έλεγχο της κλιμακωσιμότητας (scalability) του μοντέλου λόγω του μεγάλου πλήθους γράφων.

Στον Πίνακα I παρουσιάζονται τα βασικά στατιστικά χαρακτηριστικά των συνόλων δεδομένων που χρησιμοποιήθηκαν.

Table I: Στατιστικά Στοιχεία των Datasets

| Dataset    | Γράφοι | Κλάσεις | Μέσοι Κόμβοι | Πεδίο  |
|------------|--------|---------|--------------|--------|
| ENZYMES    | 600    | 6       | 32.6         | Bio    |
| IMDB-MULTI | 1500   | 3       | 13.0         | Social |
| REDDIT-12K | 11929  | 11      | 391.4        | Social |

#### IV. Πειραματικό Στήσιμο

Για τις μη επιβλεπόμενες μεθόδους, τα παραγόμενα embeddings χρησιμοποιούνται ως είσοδος σε κλασικούς ταξινομητές μηχανικής μάθησης και αλγορίθμους ομαδοποίησης. Για τη μέθοδο GIN, το μοντέλο εκπαιδεύεται με επιβλεπόμενο τρόπο από άκρο σε άκρο. Η αξιολόγηση πραγματοποιείται με χρήση κατάλληλων μετρικών απόδοσης.

##### A. Βήματα εκτέλεσης

Ακολουθήστε τον [σύνδεσμο](#) που θα σας οδηγήσει στο repository του project και το README αρχείο με αναλυτικές οδηγίες δημιουργίας περιβάλλοντος εκτέλεσης και εκτέλεσης.

Όλος ο κώδικας βρίσκεται στον [σύνδεσμο](#).

#### V. Υλοποίηση Συστήματος

##### A. Λογισμικό

Η υλοποίηση πραγματοποιήθηκε σε Python, με χρήση των ακόλουθων βιβλιοθηκών:

- KarateClub για τις μεθόδους Graph2Vec και FGSD (τροποποιημένη ώστε να μπορεί να υποστηρίξει διαφορετικές συναρτήσεις πέρα της harmonic)
- custom υλοποίηση για την Fast Computation of Family of Graph Spectral Distances and Spectrum με την μέθοδο Chebyshev [1] -δεν συμμετέχει στα πειράματα λόγω ότι δεν είναι optimized όπως οι υλοποιήσεις που χρησιμοποιούν numpy, μπορείτε να την δείτε στο repository-
- Conda Enviroment για διαχείριση των dependencies των πακέτων
- PyTorch Geometric [6] για την υλοποίηση του GIN
- Scikit-learn για την εκπαίδευση και αξιολόγηση των ταξινομητών και των αλγορίθμων ομαδοποίησης

##### B. Πειραματικό Setup

Όλα τα πειράματα εκτελέστηκαν σε σύστημα βασισμένο σε CPU, με καθορισμένο αριθμό πυρήνων και διαθέσιμη μνήμη RAM. Η χρήση GPU περιόριστηκε όπου απαιτούνταν για την εκπαίδευση του μοντέλου GIN.

#### VI. Αξιολόγηση

Για την αξιολόγηση της ποιότητας των παραγόμενων embeddings, εκτελέστηκαν τρία διακριτά πειραματικά σενάρια.

##### A. Ταξινόμηση Γράφων (Classification)

Η κύρια μέθοδος αξιολόγησης αφορά την ικανότητα των μοντέλων να διαχωρίζουν σωστά τις κλάσεις των γράφων.

- Για Μη-Επιβλεπόμενες Μεθόδους: Ακολουθήθηκε η τυπική διαδικασία δύο σταδίων. Αρχικά, παράγονται τα embeddings για όλους τους γράφους χωρίς χρήση ετικετών. Στη συνέχεια, τα embeddings αυτά χρησιμοποιούνται ως χαρακτηριστικά εισόδου (input features) για την εκπαίδευση ενός απλού ταξινομητή.
- Για Επιβλεπόμενες Μεθόδους: Η ταξινόμηση γίνεται end-to-end και ως μετρική χρησιμοποιείται το validation accuracy.

Καταγράφηκαν οι μετρικές **Accuracy**, **F1-Score** και **AUC**. Παράλληλα, μετρήθηκε ο υπολογιστικός φόρτος καταγράφοντας:

- 1) Τον χρόνο εκπαίδευσης (Training Time).
- 2) Τον χρόνο παραγωγής embeddings (Generation Time).
- 3) Τη μέγιστη χρήση μνήμης (Peak Memory Usage).

Τέλος, διεξήχθη ανάλυση ευαισθησίας μεταβάλλοντας τη διάσταση των embeddings για τη μελέτη της σχέσης ακρίβειας-κόστους.

##### B. Ομαδοποίηση (Clustering)

Για να εξεταστεί η δομική συνοχή των αναπαραστάσεων στον λανθάνοντα χώρο, εφαρμόστηκαν αλγόριθμοι μη-επιβλεπόμενης ομαδοποίησης στα embeddings που παρήγαγαν οι διάφορες μέθοδοι. Συγκεκριμένα, χρησιμοποιήθηκαν:

- **K-Means:** Ως η βασική μέθοδος διαμερισμού, η οποία ελαχιστοποιεί την εντός-συστάδας διακύμανση.
- **Spectral Clustering:** Για τον εντοπισμό πιο σύνθετων γεωμετρικών δομών. Η μέθοδος αυτή αξιοποιεί το φάσμα (ιδιοτιμές) του πίνακα ομοιότητας των embeddings για να πραγματοποιήσει μείωση διαστάσεων πριν την ομαδοποίηση, επιτρέποντας τον διαχωρισμό συστάδων που δεν είναι απαραίτητα κυρτές.

Η ποιότητα της ομαδοποίησης αξιολογήθηκε ποσοτικά χρησιμοποιώντας τον δείκτη **Adjusted Rand Index (ARI)**, ο οποίος μετρά τη συμφωνία μεταξύ των ευρεθέντων ομάδων και των πραγματικών ετικετών (ground truth), διορθώνοντας για την τύχη.

Για την ποιοτική αξιολόγηση, χρησιμοποιήθηκαν τεχνικές μείωσης διαστάσεων **t-SNE** και **UMAP** για την οπτικοποίηση των embeddings σε 2 διαστάσεις, με στόχο να διαπιστωθεί οπτικά ποια

μέθοδος επιτυγχάνει τον καθαρότερο διαχωρισμό των κλάσεων.

### C. Ανάλυση Ευστάθειας (Stability Analysis)

Η ευστάθεια των μεθόδων εξετάστηκε μέσω της εισαγωγής τεχνητού θορύβου (perturbations) στους γράφους εισόδου. Εφαρμόστηκαν οι εξής διαταραχές:

- Τυχαία προσθήκη/αφαίρεση ακμών σε ποσοστό (π.χ. 5%, 10%, 15%, 20%).
- Ανακάτεμα (shuffling) των χαρακτηριστικών των κόμβων (μόνο το dataset ENZYMES έχει node attributes).

Μετά την εφαρμογή των διαταραχών, επανυπολογίστηκαν τα embeddings και συγκρίθηκαν με τα αρχικά (original). Η αξιολόγηση βασίστηκε σε δύο άξονες:

- 1) **Embedding Stability Score:** Πόσο μετακινήθηκαν τα διανύσματα στον χώρο (συνήθως με χρήση συνημιτονικής ομοιότητας).
- 2) **Performance Drop:** Η πτώση στην ακρίβεια ταξινόμησης μετά τη διαταραχή.




Figure 1: Προ-ανάλυση στο ENZYMES με  $1/\lambda$  φίλτρο

## VII. FAMILY OF GRAPH SPECTRAL DISTANCES

### A. Μέθοδος, Pipeline και Επεκτάσεις

Μία εκ των τριών μεθόδων που χρησιμοποιούμε είναι η FGSD, η οποία χρησιμοποιεί φασματικές αποστάσεις ώστε να δημιουργήσει τα διανύσματα των γράφων. Οι φασματικές αποστάσεις λαμβάνονται από τον Λαπλασιανό πίνακα του πίνακα γειτνίασης του γράφου. Η φασματική απόσταση ορίζεται ως

$$\mathcal{S}_f(x, y) = \sum_{k=0}^{N-1} f(\lambda_k) (\phi_k(x) - \phi_k(y))^2$$

όπου  $f(\lambda_k)$  είναι η τιμή μιας συνάρτησης για την ιδιοτιμή  $\lambda_k$  του πίνακα Λαπλασιανού πίνακα,  $\phi_k(x)$  η  $x$  συνιστώσα του ιδιοδιανύσματος  $\lambda_k$ .

Αποδεικνύεται ότι:

$$\begin{aligned} \mathcal{S}_f(x, y) &= \sum_{k=0}^{N-1} f(\lambda_k) (\phi_k(x) - \phi_k(y))^2 \\ &= \sum_{k=0}^{N-1} f(\lambda_k) (\phi_k(x)^2 - 2\phi_k(x)\phi_k(y) + \phi_k(y)^2) \\ &= M_{xx} - 2M_{xy} + M_{yy} \\ &= M_{xx} + M_{yy} - 2M_{xy} \end{aligned}$$

όπου ο πίνακας  $M$  είναι ο  $f(L)$ . [1]

Συνεπώς, για να υπολογίσουμε την φασματική απόσταση μας αρκεί να υπολογίσουμε το πίνακα  $f(L)=M$ . Γνωρίζουμε πως:  $f(L) = Uf(\Lambda)U^T$

και άρα θα πρέπει να υπολογίσουμε τις ιδιοτιμές και τα ιδιοδιανύσματα του Λαπλασιανού πίνακα. Η υλοποίηση του παραπάνω αλγορίθμου υφίσταται στην Open Source βιβλιοθήκη Karate Club, μόνο για αρμονική ( $1/\lambda$ ) συνάρτηση φασματικού φίλτρου -με χρήση ψευδοαντιστρόφου που υπολογίζει κατευθείαν την  $f(L)$  για αρμονικό φίλτρο-. Τροποποιήσαμε την βιβλιοθήκη για να εκτελεί τον ίδιο αλγόριθμο και για πολυώνυμο δεύτερου βαθμού ( $\lambda^2$ ) αλλά και δι-αρμονικό φίλτρο ( $1/\lambda^2$ ).

Κάθε φίλτρο αναδεικνύει διαφορετικά χαρακτηριστικά. Φθίνουσες συναρτήσεις δίνουν το global structure του γράφου, ενώ αύξουσες το local structure. Η harmonic είναι η πιο σταθερή [1]. Εμείς πειραματιστήκαμε με αυτές και καταλήξαμε στα δικά μας συμπεράσματα. Ο υπολογισμός της συνάρτησης του Λαπλασιανού πίνακα λόγω υπολογισμού ιδιοτιμών και ιδιοδιανυσμάτων (LAPACK Algorithm by numpy) έχει υπολογιστική πολυπλοκότητα  $O(N^3)$  όπου  $N$  διάσταση του πίνακα γειτνίασης. Αυτό είναι πολύ κοστοβόρο για μεγάλα datasets γράφων όπως το Reddit-MULTI-12K και μας οδήγησε στην διερεύνηση της υλοποίησης αλλά και του pipeline των δεδομένων ώστε να αποφύγουμε περιττό grid search.

Μετά τον τελικό υπολογισμό των αποστάσεων, καλούμαστε να επιλέξουμε το πλήθος των bins και το εύρος τους, καθώς η δημιουργία των embeddings βασίζεται στην απαρίθμηση των αποστάσεων. Έτσι, δημιουργούμε ιστογράμματα που κάθε στήλη είναι ένα πλήθος ενός συγκεκριμένου εύρους αποστάσεων. Για την σωστή επιλογή, υλοποιήσαμε στην μέθοδο, μια φάση προ-ανάλυσης των embeddings, όπου λαμβάνουμε μετρικές και με την χρήση ευρετικής συνάρτησης επιλέγουμε το κατάλληλο πλήθος bins και το εύρος τους. Ο στόχος είναι η ύπαρξη ισορροπίας ώστε τα embeddings να είναι όσο το δυνατόν πιο καλή καταγραφή της γεωμετρίας του γράφου. Υπολογίζουμε φασματικές αποστάσεις με την διαδικασία που περιγράφηκε παραπάνω. Λαμβάνουμε όλες τις αποστάσεις για να προσδιορίσεται το p99 τους. Διώχνουμε ακραίες τιμές που ενδεχομένως θα χαλάσουν τα embeddings. Χρησιμοποιούμε ευρετική συνάρτηση ώστε αυτή να εξισορροπεί το πλήθος bins με τη στατιστική εγκυρότητα

(πυκνότητα δεδομένων). Οι συντελεστές λειτουργούν ως «ποινές», αν ένας κάδος έχει κατά μέσο όρο λίγα δεδομένα ( $\text{avg\_hits} < 2.0$ ), το σκορ μειώνεται δραστηρικά. Αυτό αποτρέπει ότι το ιστόγραμμα δεν θα είναι αραιό ή γεμάτο θόρυβο.

$$\text{Score}(b) = \text{avg\_hits} \cdot \ln(b) \cdot P(\text{avg\_hits})$$

$$P(x) = \begin{cases} 1.0, & x \geq 2.0 \\ 0.8, & 1.0 \leq x < 2.0 \\ 0.5, & 0.5 \leq x < 1.0 \\ 0.2, & x < 0.5 \end{cases}$$

- *avgHits*: Ο μέσος όρος τιμών σε κάθε bin.
- *b*: Ο αριθμός των κάδων (*test\_bins*).

1) Βελτίωση για δεδομένα κόμβων

Όπως αναφέρθηκε και παραπάνω, το dataset Enzymes μας προσφέρει χρήσιμη πληροφορία στους κόμβους των γράφων. Αυτό η μέθοδος FGSD αδυνατεί να το αξιοποιήσει. Για αυτό τον λόγο, δοκιμάσαμε να εμπλουτίσουμε το graph embedding συνενώνοντας το με ένα bag of words. Το bag of words αυτό περιέχει τρεις θέσεις και μας λέει πόσες φορές εντοπίζουμε στο εκάστοτε ένζυμο την εκάστοτε από τις τρεις πιθανές ουσίες, πρωτεΐνη. Προφανώς δεν θα χρησιμοποιηθεί στην σύγκριση των μεθόδων μεταξύ τους.

2) Υβριδική αναπαράσταση για διαφορετικά χαρακτηριστικά

Γνωρίζουμε [1] πως οι διαφορετικές συναρτήσεις  $f$  μας δίνουν διαφορετικά χαρακτηριστικά. Οι αύξουσες συναρτήσεις μας δίνουν local χαρακτηριστικά, ενώ οι φθίνουσες global χαρακτηριστικά για τους γράφους. Για να συγκεντρώσουμε όλη την πληροφορία, ως hybrid ορίζουμε το παρακάτω embedding-συνένωση: harmonic || polynomial.

3) Προσέγγιση της συνάρτησης του Λαπλασιανού πίνακα για την μείωση της υπολογιστικής πολυπλοκότητας με Chebyshev Approximation

Η ιδιοανάλυση της κλασσικής μεθόδου FGSD που χρησιμοποιεί και η υλοποίηση του KarateClub είναι μια πολύ κοστοβόρα διαδικασία με πολυπλοκότητα  $O(N^3)$ . Για αυτό προτείνεται [1] το Chebyshev Approximation ως λύση. Η μέθοδος αυτή προσεγγίζει τη φασματική συνάρτηση  $f(L)$  μέσω μιας πεπερασμένης σειράς πολυωνύμων Chebyshev. Υλοποιήσαμε σε Python το Chebyshev Approximation, παράγοντας αρκετά αξιόπιστα embeddings συγκριτικά με την baseline μέθοδο όπως φαίνεται από το cosine similarity που μας παρουσιάζεται στον πίνακα II. Παρότι ρίξαμε την πολυπλοκότητα σε  $O(N * K)$ , όπου  $K$ , ο βαθμός του πολυωνύμου προσέγγισης και  $E$  ο αριθμός των ακμών του γράφου, βλέπουμε πως οι επιδόσεις δεν είναι οι επιθυμητές. Αυτό συμβαίνει, καθώς η ιδιοανάλυση στην υλοποίηση γίνεται με χρήση της βιβλιοθήκης NumPy, η οποία εκτελεί βελτιστοποιημένο κώδικα C ενώ η υλοποίησή μας είναι σε Python.

Επίσης, η πλειοψηφία των datasets μας έχουν μικρού μεγέθους γράφους, το οποίο δεν βοηθάει, καθώς παρατηρήσαμε πως για να είναι σωστή η προσέγγιση κοντά στο μηδέν σε φίλτρα όπως το Harmonic ( $1/\lambda$ ) πρέπει το  $K$  να είναι  $>150$  για να μην χάσουμε πολύ σε ακρίβεια όπως με  $K=50$ , αυτό σημαίνει πως το  $K*N$  για μεγάλα  $K$  προσεγγίζει το  $O(N^2)$ . Συνεπώς, αυτή η μέθοδος δεν χρησιμοποιήθηκε περαιτέρω, ωστόσο αποτελεί πηγή έμπνευσης ως future work.

Table II: Harmonic Filter ( $1/x$ ) Comparison: Exact vs Approx with orders  $K = 50$  and  $K = 200$ .

| Dataset | Order ( $K$ ) | Exact (s)   | Approx (s)  | Sim.         |
|---------|---------------|-------------|-------------|--------------|
| ENZYMES | 50            | 2.73        | <b>1.68</b> | 0.764        |
|         | 200           | <b>1.20</b> | 2.62        | <b>0.872</b> |
| IMDB-M  | 50            | 3.90        | <b>2.46</b> | 0.286        |
|         | 200           | <b>2.41</b> | 3.26        | <b>0.960</b> |

## B. Πειραματικό Στήσιμο για FGSD

Για τον πειραματισμό με την μέθοδο, τα παραγόμενα embeddings τα χρησιμοποιούμε σε μοντέλα ταξινόμησης και ομαδοποίησης. Εφαρμόζουμε ανάλυση σταθερότητας για τους διάφορους κόμβους των γράφων. Επίσης δοκιμάζουμε υβριδικά embeddings με συνδυασμούς φίλτρων. Επίσης εφαρμόσαμε εξερεύνηση στο χώρο των υπερπαραμέτρων των μοντέλων για να δούμε που αποδίδουν καλύτερα τα embeddings.

## C. Πειραματικό Setup για FGSD

Για τα πειράματα με την μέθοδο FGSD, τα πειράματα εκτελέστηκαν σε φορητό υπολογιστή Intel I5 με 8 vCores και 8 GB RAM και 10GB Swapfile. Τα πειράματα δεν έγιναν σε απομονωμένο περιβάλλον. Η εξαρτήσεις διαχειρίστηκαν με Miniconda.

## D. Βήματα προ-εργασίας πειραμάτων Ταξινόμησης - Ροή Εκτέλεσης - Pipeline

Η πειραματική διαδικασία ξεκινά με το pre-analysis, όπου δειγματοληπτούνται 400 γράφοι από το dataset και υπολογίζονται οι φασματικές αποστάσεις για τις φασματικές συναρτήσεις (harmonic, polynomial, biharmonic), προκειμένου να προσδιοριστεί το p99 που καθορίζει το range των τιμών που θα λάβουμε υπ'όψην, ώστε να αποφύγουμε ακραίες τιμές που αν λάβουμε υπ'όψην θα οδηγήσουν σε ανομοιομορφα bins. Για κάθε συνάρτηση επιλέγεται μία τιμή και χρησιμοποιείται ως το τέλος των πειραμάτων. Αφού επιλεχθούν τα ranges, ως πλήθος bins επιλέγονται οι τρεις καλύτερες τιμές σε score από την συνάρτηση που αναλύθηκε στο VII-A.

Το επόμενο βήμα είναι να κάνουμε ελαφρύ tuning τους classifiers μας σε κάποιες χειροκίνητα επιλεγμένες υπερπαραμέτρους για την μέθοδο. Προκύπτει πως 'max\_depth': 20, 'max\_features': 'sqrt', 'min\_samples\_split': 2, 'n\_estimators': 500 για Random Forest






Figure 2: Διαστάσεις vs Accuracy με την μέθοδο FGSD. **Classifier Hyperparameters:** SVM (RBF):  $C = 100$ ,  $\gamma = \text{scale}$ . **Random Forest:**  $n_{\text{estimators}} = 500$ ,  $\text{max\_depth} = 20$ . **MLP:** layers=(256, 128, 64),  $\text{max\_iter} = 1000$ ,  $\text{early\_stop} = \text{True}$

και `'svc__C': 10`, `'svc__gamma': 0.1`, `'svc__kernel': 'rbf'` για SVM, είναι configurations που έχουν καλές επιδόσεις στα FGSD embeddings σε όλα τα datasets. Από εδώ και κάτω είναι τα μοντέλα που χρησιμοποιούνται.

Σε όλα τα πειράματα τα ranges παραμένουν σταθερά και είναι αυτά που μας δίνει το  $p_{99}$  στην προ-ανάλυση. Για το ENZYMES  $\text{harmonic\_range} = 30.3$ ,  $\text{polynomial\_range} = 4$ . Για το IMDB  $\text{harmonic\_range} = 3.5$ ,  $\text{polynomial\_range} = 3.1$ . Και για το REDDIT  $\text{harmonic\_range} = 14.61$ ,  $\text{polynomial\_range} = 3.48$ ,  $\text{biharmonic\_range} = 500$ .

### E. Ανάλυση Διαστάσεων-Ακρίβειας Μοντέλου

Από τα προηγούμενα βήματα κρατάμε τις τιμές του preanalysis και προχωράμε στην ανάλυση της σχέσης διάστασης των embeddings και υπολογιστικού κόστους και ακρίβειας των μοντέλων.

Συνήθως η αύξηση του διανύσματος ισοδυναμεί με αύξηση της ευκρίνειας των δεδομένων, ωστόσο στην μέθοδο FGSD η αύξηση της ευκρίνειας οδηγεί sparse vectors. Τα sparse vectors χάνουν την δυνατότητα να περιγράφουν "το σχήμα" του γράφου. Τα μη-δενικά δεν μεταφέρουν ακριβή πληροφορία στα μοντέλα. Για παράδειγμα στο imdb-multi, αν έχω sparse vector, τότε εικάζουμε πως θα είναι πολύ δύσκολο για το μοντέλο να διαχωρίσει ένα comedy με ένα romance διότι λόγω sparsity θα έχουμε αραιές τιμές σε ήδη αραιούς γράφους. Μοντέλα ταξινόμησης (π.χ. SVM, MLP) αντιμετωπίζουν κάθε bin ως ανεξάρτητο χαρακτηριστικό και αγνοούν τη σχέση μεταξύ γειτονικών bins, έτσι sparse vectors παρότι πολύ κοντινά, ενδέχεται τα μοντέλα να μην γενικεύουν ότι αποτελούν ίδιας κλάσης embeddings.

Στο fig 2 παρατηρούμε αυτή την αστάθεια που δημιουργούν τα μηδενικά και στα τρία datasets. Πιο πολύ βλέπουμε πως επηρεάζονται οι συναρτήσεις harmonic και biharmonic (στο Reddit μόνο). Χαρακτηριστική είναι η πτώση του MLP όταν αυξάνεται το sparsity. Το Random Forest αποτελεί το πιο robust μοντέλο.

### F. Ανάλυση Διαστάσεων-Υπολογιστικού κόστους

Είναι λογικό αν αυξήσουμε τα bins, το πλήθος των πράξεων που πρέπει να κάνουμε για να

δημιουργηθούν τα embeddings αυξάνεται. Λόγω όμως της χρήσης της βιβλιοθήκης numpy τα sparse vectors γίνονται πολύ αποδοτικά handle.

Για να εξακριβώσουμε τα trade-offs που υπάρχουν θα χρειαστεί να εφαρμόσουμε Design Space Exploration με την βοήθεια διαγραμμάτων Pareto. Κάθε bullet αναπαριστά ένα dimension size.

Βλέπουμε πως από το pareto frontier του fig. 3 ποιες είναι οι καλύτερες επιλογές ανάλογα τα trade-offs που θέλουμε να κάνουμε. Για το ENZYMES η pareto frontier της Polynomial ανήκει στο ολικό pareto frontier εξ' ολοκλήρου, στο IMDB το harmonic είναι αυτό που το καταφέρει ενώ στο Reddit, κάθε φίλτρο δίνει κάτι διαφορετικό καθώς και τα τρία είναι στο global frontier. Ωστόσο λόγω της απουσίας τάξεως μεγέθους διαφοράς μεταξύ των χρόνων, είναι ξεκάθαρο πως σε κάθε επιλογή πρέπει να επιλεχθεί το dimension size με το μεγαλύτερο accuracy στο classification task.

Ομοίως και για την μνήμη, λόγω ότι το accuracy μένει σαν maximizing ποσότητα βλέπουμε πως σχεδόν παντού οι ίδιες τιμές παραμένουν στο global frontier. Οι διαφορές στην χρήσης της μνήμης είναι κοντινές και άρα πάλι αξίζει να επιλέξουμε με βάση το accuracy. fig. 4

Βέβαια βλέπουμε πως το κόστος του Reddit είναι πολύ υψηλότερο από τα άλλα, χωρίς να λογαριάζεται στο σχήμα και στον πίνακα, το overhead της επεξεργασία σε batches καθώς στον υπολογιστή που έγιναν τα πειράματα, το dataset αυτό δεν χωρούσε ολόκληρο στην κύρια μνήμη. Η επεξεργασία έγινε σε 24 batches.

Να σημειωθεί ότι οι μετρήσεις έγιναν με την χρήση των συναρτήσεων `tracemalloc.start()`, `time.time()` αφού πρώτα ζητήθηκε από το Garbage Collector της Python να καθαρίσει το heap. Η `tracemalloc` παρακολουθεί τη μνήμη που δεσμεύει ο Python Memory Allocator. Η numpy είναι σε C, οπότε η χρήση της δεν μπορεί να παρατηρηθεί με αυτόν τον τρόπο.

### G. Απόδοση Ταξινόμησης

Στην ενότητα αυτή παρουσιάζονται τα αποτελέσματα ταξινόμησης για κάθε configuration και σύνολο δεδομένων.

Παρατηρούμε ότι το Polynomial Filter επιτυγχάνει σταθερά τις υψηλότερες επιδόσεις στα datasets




Figure 3: Pareto ανάλυση Accuracy vs Time για τα τρία datasets με Random Forest Classifier




Figure 4: Pareto ανάλυση Accuracy vs Memory Use για τα τρία datasets με Random Forest Classifier

ENZYMES και IMDB-MULTI. Τα dataset αυτά αποτελούνται από λίγους γράφους, Αυτό υποδηλώνει ότι το Polynomial φίλτρο έχει την ικανότητα να συλλαμβάνει πιο σύνθετα δομικά μοτίβα local structures σε σχέση με το Harmonic, προσφέροντας καλύτερη διαχωριστική ικανότητα στα embeddings. Θεωρούμε πως αυτό είναι σημαντικό στο Enzymes και το IMDB τα οποία είναι μικρά datasets που δεν βασίζονται στο σχήμα του γράφου αλλά στις σχέσεις μεταξύ λίγων κόμβων που πιθανόν να δημιουργούν και κύκλους.

Αντίθετα, βλέπουμε πως στο Reddit κυριαρχεί η Harmonic και τα hybrid που την περιλαμβάνουν. Αυτό συμβαίνει διότι το Reddit dataset βασίζεται παρά πολύ στο σχήμα του γράφου για την διάκριση. Ένας γράφος star είναι πιθανό να είναι στην κατηγορία AskReddit όπου πολλοί θα πουν την γνώμη του αλλά δεν θα λάβουν απάντηση, ενώ ένα Sparse γράφος είναι πολύ πιθανό να είναι στην κατηγορία Politics όπου και λίγες απαντήσεις μπορεί να οδηγήσουν σε μακροσκελή debates. **III**

Αξίζει να σημειωθεί η βελτίωση που λαμβάνει το ENZYMES με την χρήση της πιο naive (concat) αναπαράστασης. Η μέθοδος FGSD αδυνατεί από μόνη της να κάνει capture τα attributes των κόμβων, έτσι προκύπτει η βελτίωση του bag of words στον πίνακα **IV**.

## H. Ανάλυση Σταθερότητας

Για να αναλύσουμε την σταθερότητα των embeddings, εφαρμόζουμε random add/remove (0.01,0.05,0.1,0.2) και ολικό ανακάτεμα στον attributes στο Enzymes DS.

Παρατηρούμε πως παρότι στο Enzymes dataset, το polynomial φίλτρο δίνει πιο κοντινά embeddings καθώς στις περισσότερες περιπτώσεις το cosine similar-

ity του είναι μεγαλύτερο, βλέπουμε να επιβεβαιώνεται η θέση του **[1]** όπου αναφέρει την Harmonic ως την πιο stable επιλογή. Όπως είναι λογικό, το reshuffle δεν επηρεάζει καθόλου καθώς η default μέθοδος δεν λαμβάνει υπ' όψη τα node attributes και η απλή επέκταση με bag of words απλώς τα απαριθμεί. Ομοίως και για το IMDB. **V, VI**

Ενδιαφέρον παρουσιάζει το stability στο Reddit DS, εκεί βλέπουμε πως το Polynomial είναι σαφώς πιο σταθερό. Θεωρούμε πως αυτό συμβαίνει, καθώς το local structure που δίνει το Polynomial φίλτρο, δεν επηρεάζει εν γένει το Reddit, αφού όπως είδαμε και παραπάνω, το harmonic είναι το φίλτρο με τις καλές επιδόσεις καθώς δίνει global-σχηματική πληροφορία. **VII**

## I. Απόδοση σε Clustering Tasks

Για τη διερεύνηση της δομής των embeddings, εφαρμόστηκε διαδικασία Grid Search στο pipeline, εξετάζοντας συνδυασμούς προ-επεξεργασίας (raw embeddings, l2 norm., StandardScaler, MinMaxScaler, PCA=0.8,0.9,0.95,0.99 και αλγορίθμων (K-Means, Spectral Clustering). Στόχος ήταν ο εντοπισμός της βέλτιστης διαμόρφωσης.

Για το dataset enzymes, η μέθοδος βρίσκει ισχυρή δομική συνοχή και για αυτό έχουμε υψηλές τιμές στο Silhouette, αλλά αυτή η δομή δεν ταυτίζεται με τις λειτουργικές ετικέτες των ενζύμων και άρα έχουμε χαμηλό ARI.

Στο IMDB, ενώ καταγράφονται οι υψηλότερες τιμές Silhouette, το ARI παραμένει σχεδόν μηδενικό. Το μοντέλο διαχωρίζει επιτυχώς τους γράφους βάσει τοπολογικών χαρακτηριστικών (π.χ., πυκνότητα, κλίκες), ωστόσο τα χαρακτηριστικά αυτά

Table III: Σύγκριση επίδοσης στην ταξινόμηση των FGSD embeddings. Να σημειωθεί

| Dataset    | Filter / Method | Classifier    | Dim  | Gen. Emb. Time (s) | Gen. Emb. Memory Usage (MB) | Accuracy      | F1-Score      | AUC           |
|------------|-----------------|---------------|------|--------------------|-----------------------------|---------------|---------------|---------------|
| ENZYMES    | Polynomial      | Random Forest | 150  | 4.41               | 2.09                        | <b>0.5444</b> | <b>0.5395</b> | <b>0.7845</b> |
|            | Polynomial      | Random Forest | 100  | 7.49               | 1.78                        | 0.5333        | 0.5339        | 0.7760        |
|            | Polynomial      | Random Forest | 50   | 5.71               | 1.60                        | 0.5000        | 0.4992        | 0.7753        |
|            | Hybrid (Naive)  | MLP           | 150  | -                  | -                           | 0.4444        | 0.4480        | 0.7659        |
|            | Polynomial      | SVM (RBF)     | 200  | 3.50               | 2.49                        | 0.4111        | 0.3972        | 0.6797        |
| IMDB-MULTI | Polynomial      | MLP           | 150  | 6.90               | 3.99                        | <b>0.5200</b> | <b>0.4981</b> | <b>0.6754</b> |
|            | Harmonic        | MLP           | 100  | 6.64               | 2.93                        | 0.5022        | 0.4784        | 0.6650        |
|            | Polynomial      | Random Forest | 200  | 6.67               | 5.04                        | 0.4978        | 0.4818        | 0.6688        |
|            | Harmonic        | MLP           | 50   | 7.28               | 1.88                        | 0.4933        | 0.4794        | 0.6396        |
|            | Hybrid (Naive)  | SVM (RBF)     | 250  | -                  | -                           | 0.4844        | 0.4735        | 0.6414        |
| REDDIT-12K | Harmonic        | Random Forest | 500  | 2804.82            | 52.33                       | <b>0.4570</b> | 0.4363        | 0.8487        |
|            | Hybrid (Biharm) | Random Forest | 1000 | -                  | -                           | <b>0.4570</b> | 0.4322        | 0.8548        |
|            | Hybrid (Naive)  | Random Forest | 1000 | -                  | -                           | 0.4559        | <b>0.4365</b> | <b>0.8553</b> |
|            | Polynomial      | MLP           | 200  | 2805.36            | 63.71                       | 0.4235        | 0.3936        | 0.8439        |
|            | Polynomial      | SVM (RBF)     | 200  | 2805.36            | 63.71                       | 0.3939        | 0.3616        | 0.8251        |

Table IV: Performance Bag of Words Modified FGSD with Node Labels (ENZYMES only).

| Dataset | Filter / Method | Classifier    | Dim | Gen. Emb. Time (s) | Gen. Emb. Memory Usage (MB) | Accuracy      | F1-Score      | AUC           |
|---------|-----------------|---------------|-----|--------------------|-----------------------------|---------------|---------------|---------------|
| ENZYMES | Polynomial      | Random Forest | 103 | 7.49               | 1.78                        | <b>0.5889</b> | <b>0.5890</b> | 0.8150        |
|         | Polynomial      | Random Forest | 53  | 5.71               | 1.60                        | 0.5778        | 0.5769        | <b>0.8178</b> |
|         | Polynomial      | Random Forest | 203 | 3.50               | 2.49                        | 0.5444        | 0.5409        | 0.8013        |
|         | Harmonic        | SVM (RBF)     | 153 | 7.56               | 2.07                        | 0.4222        | 0.4174        | 0.7154        |
|         | Harmonic        | MLP           | 253 | 7.44               | 2.86                        | 0.4000        | 0.3933        | 0.7000        |

Table V: Ανάλυση Σταθερότητας στο ENZYMES dataset: Harmonic vs Polynomial. "Sim" == Cosine Similarity, "Drop" == RF Accuracy Drop.

| Perturbation         | Ratio (%) | Harmonic      |              | Polynomial    |              |
|----------------------|-----------|---------------|--------------|---------------|--------------|
|                      |           | Sim.          | Drop (%)     | Sim.          | Drop (%)     |
| Edge Add             | 1         | 0.8468        | <b>0.00</b>  | <b>0.9416</b> | 2.17         |
|                      | 5         | 0.7726        | <b>15.79</b> | <b>0.8939</b> | 26.09        |
|                      | 10        | 0.6783        | 31.58        | <b>0.7296</b> | <b>21.74</b> |
|                      | 20        | <b>0.5602</b> | <b>28.95</b> | 0.4421        | 30.43        |
| Edge Remove          | 1         | 0.9216        | <b>10.53</b> | <b>0.9421</b> | 23.91        |
|                      | 5         | 0.8853        | <b>21.05</b> | <b>0.9061</b> | 28.26        |
|                      | 10        | <b>0.8439</b> | <b>23.68</b> | 0.7887        | 54.35        |
|                      | 20        | <b>0.7849</b> | <b>31.58</b> | 0.5540        | 47.83        |
| <b>Node Shuffle*</b> | 100       | -             | -            | <b>1.0000</b> | <b>0.00</b>  |

\*Node Shuffle result refers to Polynomial (+Labels).

Table VI: Ανάλυση Σταθερότητας στο IMDB dataset: Harmonic vs Polynomial. "Sim" == Cosine Similarity, "Drop" == RF Accuracy Drop.

| Perturbation | Ratio (%) | Harmonic      |              | Polynomial    |              |
|--------------|-----------|---------------|--------------|---------------|--------------|
|              |           | Sim.          | Drop (%)     | Sim.          | Drop (%)     |
| Edge Add     | 1         | 0.7375        | 2.73         | <b>0.8419</b> | <b>0.89</b>  |
|              | 5         | 0.7001        | 4.55         | <b>0.7792</b> | <b>-0.89</b> |
|              | 10        | 0.6573        | <b>0.00</b>  | <b>0.6971</b> | 0.89         |
|              | 20        | 0.6129        | <b>2.73</b>  | <b>0.6259</b> | 7.14         |
| Edge Remove  | 1         | <b>0.8061</b> | <b>-0.91</b> | 0.7485        | 1.79         |
|              | 5         | <b>0.7699</b> | <b>3.64</b>  | 0.6422        | 7.14         |
|              | 10        | <b>0.7199</b> | <b>-3.64</b> | 0.3936        | 0.89         |
|              | 20        | <b>0.6311</b> | <b>-1.82</b> | 0.1782        | 8.93         |

δεν επαρκούν για τη διάκριση των κινηματογραφικών ειδών, τα οποία απαιτούν πιο σύνθετη συσχέτιση.

Στο dataset REDDIT-MULTI σημειώνεται η υψηλότερη τιμή ARI (0.091), γεγονός που υποδεικνύει ότι η τοπολογία των γράφων των διαλόγων φέρει μερική πληροφορία για την προέλευση του subreddit.

Τα visualizations t-SNE και UMAP παρουσιάζονται στο APPENDIX 12, 13, 14.

Από τα visualizations, βλέπουμε πως τα Ground Truth καταδεικνύουν πόσο μπερδεμένες είναι οι κλά-

Table VII: Ανάλυση Σταθερότητας στο REDDIT dataset: Harmonic vs Polynomial. "Sim" == Cosine Similarity, "Drop" == RF Accuracy Drop.

| Perturbation | Ratio (%) | Harmonic      |          | Polynomial    |              |
|--------------|-----------|---------------|----------|---------------|--------------|
|              |           | Sim.          | Drop (%) | Sim.          | Drop (%)     |
| Edge Add     | 5         | 0.8926        | 4.16     | <b>0.9627</b> | <b>1.89</b>  |
|              | 10        | 0.8468        | 5.26     | <b>0.9177</b> | <b>-1.39</b> |
| Edge Remove  | 5         | 0.9217        | 2.08     | <b>0.9236</b> | <b>0.50</b>  |
|              | 10        | <b>0.8598</b> | 2.57     | 0.8415        | <b>0.63</b>  |

σεις. Συγκρίνοντας τα UMAP και t-SNE, βλέπουμε πως αδυνατούν να προσδιορίσουν τις μπερδεμένες κλάσεις, εξ' ου και το χαμηλό ARI, αλλά βλέπουμε να σχηματίζουν ομάδες, εξ' ου και το υψηλό Silhouette. Το πιο δύσκολο χαρακτηριστικό είναι η απόσταση που βλέπουμε στο GT για ίδιες κλάσεις. Φαίνεται ξεκάθαρα στο REDDIT, είτε local (t-sne) είτε global πληροφορία (umap) έχουν ανακατεμένες κλάσεις.

Σε αυτό ευθύνεται και η μέθοδος μας η οποία δεν δίνει πληροφορία για τον τρόπο σύνδεσης παρά μόνο για τις αποστάσεις, το οποίο σημαίνει πως το φάσμα το οποίο μπορεί να ένας clustering αλγόριθμος να καλύψει ως μία ομάδα, είναι πιθανό να αστοχεί.

#### J. Raw Embeddings vs StandardScaler

Τα αποτελέσματα του πίνακα IX μας δείχνουν ότι η χρήση StandardScaler είναι περιττή, καθώς το μοντέλο επέδειξε πλήρη ανθεκτικότητα. Αντιθέτως, στην περίπτωση του Hybrid διανύσματος, η κανονικοποίηση λειτουργήσε αρνητικά (-0.03) και στα δύο datasets, καθώς η εξίσωση της διακύμανσης σε ετερογενή χαρακτηριστικά (concatenated vectors) ενίσχυσε τεχνητά τον θόρυβο έναντι της χρήσιμης πληροφορίας. Συνεπώς, τα Raw embeddings προκρίνονται ως βέλτιστη επιλογή, διατηρώντας τη φυσική σημασία των φασματικών τιμών σε hybrid embeddings, ωστόσο δεν επηρεάζει τα embeddings που

Table VIII: Συγκεντρωτικά αποτελέσματα ομαδοποίησης για τα datasets ENZYMES, IMDB-MULTI και REDDIT-MULTI στον αρχικό χώρο PCA (HD).

|                              |            |          | PCA Space (HD) |              |
|------------------------------|------------|----------|----------------|--------------|
| Method                       | Params     | Algo     | ARI            | Sil          |
| <i>Dataset: ENZYMES</i>      |            |          |                |              |
| Harmonic (100, 30.3)         | L2, 0.99   | Spectral | <b>0.0432</b>  | 0.163        |
| Harmonic (50, 30.3)          | L2, 0.99   | Spectral | 0.0424         | 0.207        |
| Harmonic (100, 30.3)         | L2, 0.95   | K-Means  | 0.0292         | <b>0.295</b> |
| Hybrid (150/100)             | Std, 0.99  | K-Means  | 0.0144         | 0.276        |
| Polynomial (150, 3.8)        | Std, 0.99  | Spectral | 0.0341         | 0.003        |
| <i>Dataset: IMDB-MULTI</i>   |            |          |                |              |
| Harmonic (100, 3.52)         | L2, 0.95   | K-Means  | 0.0058         | 0.344        |
| Hybrid (150/200)             | Std, 0.95  | K-Means  | 0.0008         | <b>0.574</b> |
| Polynomial (150, 3.1)        | L2, 0.99   | K-Means  | 0.0062         | 0.328        |
| Hybrid (150/200)             | Std, 0.99  | Spectral | <b>0.0199</b>  | 0.076        |
| Polynomial (200, 3.1)        | L2, 0.95   | Spectral | 0.0141         | 0.302        |
| <i>Dataset: REDDIT-MULTI</i> |            |          |                |              |
| Hybrid (100/100)             | L2, 0.99   | K-Means  | <b>0.0906</b>  | 0.124        |
| Polynomial (100, 3.5)        | L2, 0.99   | K-Means  | 0.0878         | 0.134        |
| Harmonic (100, 14.6)         | L2, 0.99   | K-Means  | 0.0817         | <b>0.142</b> |
| Harmonic (100, 14.6)         | None, 0.99 | Spectral | 0.0766         | 0.128        |
| Polynomial (100, 3.5)        | L2, 0.99   | Spectral | 0.0759         | 0.074        |

προέρχονται από το ίδιο φίλτρο καθώς στο preanalysis stage που έχουμε, οι ακραίες τιμές κόβονται.

Table IX: Σύγκριση Raw Embeddings vs Standard-Scaler

| Dataset    | Filter       | Accuracy     |       |               | F1-Score     |       |               |
|------------|--------------|--------------|-------|---------------|--------------|-------|---------------|
|            |              | Raw          | Prep  | Diff          | Raw          | Prep  | Diff          |
| IMDB-MULTI | Harmonic     | 0.489        | 0.489 | 0.000         | 0.474        | 0.474 | 0.000         |
|            | Polynomial   | 0.498        | 0.498 | 0.000         | 0.482        | 0.482 | 0.000         |
|            | Naive Hybrid | 0.502        | 0.502 | 0.000         | 0.490        | 0.490 | 0.000         |
| ENZYMES    | Harmonic     | 0.456        | 0.456 | 0.000         | 0.453        | 0.453 | 0.000         |
|            | Polynomial   | 0.544        | 0.544 | 0.000         | 0.540        | 0.540 | 0.000         |
|            | Naive Hybrid | <b>0.500</b> | 0.467 | <b>-0.033</b> | <b>0.498</b> | 0.466 | <b>-0.032</b> |

## VIII. GRAPH ISOMORPHISM NETWORKS – GIN

### A. Εισαγωγή

Το μοντέλο **Graph Isomorphism Networks (GIN)**, όπως παρουσιάστηκε από τους Xu *et al.* [5], ανήκει στην κατηγορία των Graph Neural Networks (GNNs) και σχεδιάστηκε με σκοπό να πετύχει μέγιστη εκφραστική ικανότητα, να ξεχωρίζει δηλαδή ικανοποιητικά διαφορετικές δομές και τοπολογίες γραφημάτων, όπου προηγούμενα μοντέλα όπως τα GCN [8] και GraphSAGE [9] δεν είχαν καταφέρει μεγάλες επιτυχίες.

Οι ερευνητές στο [5], αποδεικνύουν ότι τα GNNs για να πάρουν το διάνυσμα χαρακτηριστικών ενός κόμβου εφαρμόζουν μια αναδρομική διαδικασία συνάθροισης των γειτονικών κόμβων (re-

cursive neighborhood aggregation) γνωστή και ως message passing, που λειτουργεί παρόμοια με τον έλεγχο ισομορφισμού γράφων Weisfeiler-Lehman (1-WL) [10], και κατά συνέπεια κανένα GNN δεν έχει πιο ισχυρή εκφραστική ικανότητα από τον έλεγχο 1-WL, ορίζοντας έτσι ένα άνω φράγμα.

Στόχος του GIN είναι η μεγιστοποίηση της εκφραστικής ικανότητας (expressiveness), ώστε το μοντέλο να μπορεί να ξεχωρίζει μη ισομορφικούς γράφους με ακρίβεια η οποία πλησιάζει τον έλεγχο 1-WL.

### B. GNNs και Weisfeiler-Lehman

Ο έλεγχος ισομορφισμού Weisfeiler-Lehman (1-WL) [10] ανανεώνει επαναληπτικά το διάνυσμα χαρακτηριστικών κάθε κόμβου σύμφωνα με τα διανύσματα χαρακτηριστικών των γειτόνων του. Και αυτό που κάνει το WL test τόσο ισχυρό είναι η αμφιμονοσήμαντη (injective) συνάρτηση που χρησιμοποιεί για συνάθροιση (aggregation) και ενημέρωση, η οποία αντιστοιχεί κάθε "γειτονιά" κόμβων σε διαφορετικό διάνυσμα χαρακτηριστικών.

Στη μελέτη τους, οι Xu *et al.* [5], αποδεικνύουν ότι ένα GNN έχει μέγιστη εκφραστικότητα αν και μόνο αν οι συναρτήσεις συνάθροισης (aggregate) και ενημέρωσης (update) που χρησιμοποιεί είναι αμφιμονοσήμαντες (**injective**). Διασφαλίζοντας έτσι ότι διαφορετικές γειτονιές κόμβων δηλαδή πολυσύνολα



χαρακτηριστικών αντιστοιχίζονται πάντα σε διαφορετικά embeddings, χωρίς να χάνεται πληροφορία για την δομή του γράφου.

### C. Η Αρχιτεκτονική GIN

Για να υλοποιηθεί η αμφιμονοσήμαντη συνάρτηση συνάθροισης (injective aggregation function), το GIN επιλέγει να χρησιμοποιήσει τον αθροιστικό τελεστή (sum aggregator), καθώς το άθροισμα μπορεί να διακρίνει μοναδικά πολυσύνολα, σε αντίθεση με τη μέση τιμή ή το μέγιστο.

Ο κανόνας ενημέρωσης του GIN για τον κόμβο  $v$  στην επανάληψη  $k$  ορίζεται ως:

$$h_v^{(k)} = \text{MLP}^{(k)} \left( (1 + \epsilon^{(k)}) \cdot h_v^{(k-1)} + \sum_{u \in \mathcal{N}(v)} h_u^{(k-1)} \right) \quad (1)$$

όπου:

- $h_v^{(k)}$  είναι το διάνυσμα χαρακτηριστικών του κόμβου.
- $\epsilon^{(k)}$  είναι μια εκπαιδύσιμη παράμετρος (ή σταθερά).

Η θεωρητική ανάλυση στο [5] αποδεικνύει ότι οι aggregators που χρησιμοποιούνται συνήθως παρουσιάζουν τους εξής περιορισμούς:

- **Mean Pooling (GCN [8]):** Διατηρεί την κατανομή των χαρακτηριστικών αλλά όχι το πλήθος των στοιχείων, έτσι δύο γράφοι με ίδια αναλογία χαρακτηριστικών αλλά διαφορετικό πλήθος κόμβων παράγουν το ίδιο embedding.
- **Max Pooling (GraphSAGE [9]):** Ενώ εντοπίζει αντιπροσωπευτικά χαρακτηριστικά, αγνοεί την πολλαπλότητα τους (multiplicity), χάνοντας πληροφορία για την συχνότητα εμφάνισης δομικών μοτίβων.

### D. Readout Function για Graph Classification

Τα node embeddings που παράγει το GIN μπορούν να χρησιμοποιηθούν για προβλέψεις συνδέσεων (link prediction) και ταξινόμηση κόμβων (node classification). Για την ταξινόμηση ολόκληρου του γράφου, δεδομένων των node embeddings, το GIN αθροίζει τα embeddings από όλες τις επαναλήψεις  $k$ :

$$h_G = \text{CONCAT} \left( \sum_{v \in G} h_v^{(k)} \mid k = 0, 1, \dots, K \right) \quad (2)$$

Αυτή η αρχιτεκτονική επιτρέπει στο GIN να συλλέγει τόσο τα τοπικά (local) όσο και τα καθολικά (global) δομικά χαρακτηριστικά του γράφου.

### E. Υλοποίηση Μοντέλου για Πειράματα

Για την πειραματική διαδικασία, αναπτύχθηκε μια παραλλαγή του μοντέλου GIN με χρήση του framework **PyTorch Geometric** [6] και ακολουθήθηκαν πιστά οι προδιαγραφές του [5] για τη μεγιστοποίηση της εκφραστικής ικανότητας.

### F. Δομή Δικτύου

Ο πυρήνας του μοντέλου αποτελείται από πολλαπλά GIN layers. Οι βασικές επιλογές σχεδιασμού είναι οι εξής:

- 1) **trainable  $\epsilon$ :** Η υπερπαράμετρος  $\epsilon$  ορίστηκε ως εκπαιδύσιμη και όχι ως σταθερά (`train_eps=True`).
- 2) **Jumping Knowledge (JK):** Η τελική αναπαράσταση του κόμβου προκύπτει από τη συνένωση των διανυσμάτων όλων των  $k$  επιπέδων (`jk="cat"`).

### G. Readout και Ταξινόμηση

Μετά την εξαγωγή των χαρακτηριστικών των κόμβων, εφαρμόζεται η συνάρτηση **Global Sum Pooling** (`global_add_pool`) για τη δημιουργία του διανύσματος αναπαράστασης ολόκληρου του γράφου ( $h_G$ ), διατηρώντας την ιδιότητα αμφιμονοσήμαντης απεικόνισης.

Τέλος, το διάνυσμα  $h_G$  τροφοδοτείται σε ένα Classification Head, το οποίο αποτελείται από ένα MLP με την εξής δομή:

- Γραμμικό επίπεδο (Linear Layer)
- Κανονικοποίηση (Batch Normalization 1D)
- Συνάρτηση ενεργοποίησης ReLU
- Dropout (με πιθανότητα  $p = 0.5$  για αποφυγή υπερπροσαρμογής)
- Τελικό Γραμμικό επίπεδο εξόδου (Prediction Layer)

Ο παραπάνω σχεδιασμός εξασφαλίζει ότι το μοντέλο εκμεταλλεύεται πλήρως τη θεωρητική ισχύ του GIN για προβλήματα ταξινόμησης γράφων.

### H. Πειραματικό Περιβάλλον

Η ανάπτυξη, η εκπαίδευση και η αξιολόγηση του μοντέλου πραγματοποιήθηκαν στην πλατφόρμα υπολογιστικού νέφους **Google Colaboratory (Colab)**. Χρησιμοποιήθηκε η **GPU (Graphics Processing Unit)** που παρέχεται δωρεάν από την πλατφόρμα (τυπικά NVIDIA Tesla T4 με 16GB VRAM).

### I. Προεπεξεργασία Δεδομένων

Τα social datasets IMDB-MULTI και REDDIT-MULTI-12K δεν διαθέτουν χαρακτηριστικά κόμβων (node attributes), ενώ το ENZYMES έχει. Σύμφωνα με την πρόταση των Xu *et al.* [5], για να μπορέσει το GIN να επεξεργαστεί τους γράφους, είναι απαραίτητη η δημιουργία χαρακτηριστικών που βασίζονται στη δομή. Για τον σκοπό αυτό, εφαρμόστηκε η τεχνική **One-Hot Encoding** στον βαθμό (degree) κάθε κόμβου. Κάθε κόμβος  $v$  αναπαρίσταται από ένα διάνυσμα  $x_v \in \{0, 1\}^d$ , όπου η τιμή 1 τοποθετείται στη θέση που αντιστοιχεί στον βαθμό του κόμβου.

Ειδικότερα για το dataset **REDDIT-MULTI-12K**, παρατηρήθηκε ότι ορισμένοι κόμβοι (hubs) έχουν εξαιρετικά υψηλό βαθμό, γεγονός που οδηγεί στη δημιουργία πολύ αραιών διανυσμάτων (sparse vectors) μεγάλου μεγέθους. Λόγω των περιορισμών μνήμης

του περιβάλλοντος Google Colab, εφαρμόστηκε μια προσαρμοσμένη στρατηγική **Degree Clamping**.

Ορίστηκε ένα μέγιστο κατώφλι βαθμού  $D_{max} = 500$ .

$$x_v = \text{OneHot}(\min(\deg(v), 500)) \quad (3)$$

Αυτή η τεχνική μείωσε τη διάσταση των χαρακτηριστικών εισόδου, χωρίς σημαντική απώλεια πληροφορίας, καθώς οι κόμβοι με βαθμό  $> 500$  συμπεριφέρονται παρόμοια ως "υπερ-κόμβοι".

#### J. Ρυθμίσεις Εκπαίδευσης

Για την εκπαίδευση του GIN μοντέλου χρησιμοποιήθηκαν οι εξής παράμετροι, όπως ορίστηκαν στον κώδικα υλοποίησης:

Table X: Παράμετροι Εκπαίδευσης Μοντέλου GIN

| Παράμετρος        | Τιμή                  |
|-------------------|-----------------------|
| Optimizer         | Adam                  |
| Learning Rate     | 0.01                  |
| Hidden Dimensions | 64, 128               |
| Dropout Rate      | 0.5                   |
| Aggregation       | Sum                   |
| Readout Function  | Sum (Global Add Pool) |

Η εκπαίδευση έγινε με τη μέθοδο της ελαχιστοποίησης της συνάρτησης απώλειας (Loss Function) χρησιμοποιώντας τον αλγόριθμο βελτιστοποίησης **Adam**, ο οποίος προσαρμόζει τον ρυθμό μάθησης για κάθε παράμετρο ξεχωριστά.

#### K. Διαδικασία Εκπαίδευσης και Βελτιστοποίηση

Η εκπαίδευση του μοντέλου πραγματοποιήθηκε με την ελαχιστοποίηση της συνάρτησης απώλειας **Cross-Entropy Loss**. Η διαδικασία βελτιστοποίησης υλοποιήθηκε σε επαναλήψεις (epochs), χρησιμοποιώντας τη μέθοδο  $k$ -fold Cross-Validation για την αξιολόγηση της ευρωστίας του μοντέλου. Αρχικά όλες οι εκπαιδευσεις έγιναν στις 350 εποχές, ώστε να εντοπιστεί επαρκώς σε ποιο αριθμό εποχών συγκλίνει το μοντέλο.

#### L. Στρατηγική Επιλογής Μοντέλου

Κατά τη διάρκεια της εκπαίδευσης, παρατηρήθηκε **overfitting**, όπου, μετά από έναν ορισμένο αριθμό εποχών, η απώλεια στο σύνολο εκπαίδευσης συνεχίζει να μειώνεται, ενώ η απώλεια στο σύνολο επικύρωσης αρχίζει να αυξάνεται. Με αποτέλεσμα, το μοντέλο στην τελευταία εποχή ( $T_{final}$ ) να μην είναι απαραίτητα το βέλτιστο. Για την αντιμετώπιση αυτού του προβλήματος, υιοθετήθηκε η στρατηγική της αποθήκευσης και επαναφοράς Βαρών (Weight Restoration). Συγκεκριμένα:

- Σε κάθε εποχή  $t$ , καταγράφονται η απώλεια  $\mathcal{L}_{val}^{(t)}$  και η ακρίβεια  $Acc_{val}^{(t)}$  στο σύνολο επικύρωσης.
- Ορίζουμε ως βέλτιστο μοντέλο αυτό που ελαχιστοποιεί την απώλεια επικύρωσης. Αν

ισχύει  $\mathcal{L}_{val}^{(t)} < \mathcal{L}_{best}$ , τότε αποθηκεύουμε την τρέχουσα κατάσταση των παραμέτρων  $\theta^{(t)}$ :

$$\theta_{best} = \underset{\theta^{(t)}}{\operatorname{argmin}} \mathcal{L}_{val}(\theta^{(t)}), \quad \forall t \in [1, T_{max}] \quad (4)$$

- Στο τέλος της διαδικασίας εκπαίδευσης, το μοντέλο δεν κρατά τα βάρη της τελευταίας εποχής, αλλά επαναφέρεται (reloads) στην κατάσταση  $\theta_{best}$ , όπως φαίνεται και στην Εικόνα 5

Αυτή η προσέγγιση διασφάλισε ότι το τελικό μοντέλο που χρησιμοποιήθηκε για αξιολόγηση είναι αυτό με την υψηλότερη ικανότητα γενίκευσης, μεγιστοποιώντας παράλληλα την ακρίβεια ταξινόμησης και ελαχιστοποιώντας το σφάλμα πρόβλεψης.

Σε συνδιασμό με το weight restoration, εφαρμόστηκαν τρεις διαφορετικές στρατηγικές χρονοπρογραμματισμού του ρυθμού μάθησης (Learning Rate Scheduling):

##### 1) Στρατηγική A: **Step Decay**

Εξαρχής παρατηρήθηκε ότι με σταθερό ρυθμό μάθησης η απώλεια σταθεροποιούνταν σε μια τιμή (loss plateau), παρά την εφαρμογή dropout. Προκειμένου να πετύχουμε σύγκλιση των απωλειών, χρησιμοποιήθηκε το **StepLR**, που μειώνει τον ρυθμό μάθησης πολλαπλασιαστικά με συντελεστή  $\gamma$  κάθε συγκεκριμένο αριθμό εποχών. Επιλέχθηκε υποδιπλασιασμός του learning rate ανά 50 εποχές, όπως προτίνεται και στο [5].

##### 2) Στρατηγική B: **Step Decay** με Πρόωρο Τερματισμό

Όπως φαίνεται στην Εικόνα 5, η διαδικασία εκπαίδευσης φτάνει σε σημείο κορεσμού σχετικά νωρίς. Προκειμένου να μειωθεί το υπολογιστικό κόστος, χωρίς να έχει μεγάλη επίδραση στην ακρίβεια, δοκιμάστηκε η εφαρμογή **Early Stopping** με όριο ανοχής (patience) 50 εποχών. Αν το validation loss δεν βελτιώνεται για 50 συνεχόμενες εποχές, η εκπαίδευση διακοπτότεται και το μοντέλο επανέρχεται στα βάρη της βέλτιστης εποχής. Η στρατηγική αυτή αποδείχθηκε αποτελεσματική ιδιαίτερα για τα datasets όπως το REDDIT που το χρονικό κόστος ήταν κρίσιμο για την διεξαγωγή των πειραμάτων, ενώ στα υπόλοιπα datasets δεν χρησιμοποιήθηκε τελικά, καθώς δεχτήκαμε το (μικρό) trade off του κόστους προκειμένου να μεγιστοποιήσουμε την ακρίβεια ταξινόμησης.

##### 3) Στρατηγική Γ: **Cosine Annealing**

Τέλος σε μια προσπάθεια να μεγιστοποιήσουμε την ακρίβεια του GIN σε datasets, όπως το ENZYMES που είναι μικρό και θορυβώδες, δοκιμάστηκε η στρατηγική **Cosine Annealing LR** χωρίς πρόωρο τερματισμό. Σε αυτή τη διάταξη, ο ρυθμός μάθησης προσαρμόζεται ακολουθώντας τη συνάρτηση συνημιτόνου:

$$\eta_t = \eta_{min} + \frac{1}{2}(\eta_{max} - \eta_{min}) \left( 1 + \cos \left( \frac{T_{cur}}{T_{max}} \pi \right) \right) \quad (5)$$




Figure 5: Καμπύλες εκπαίδευσης και επικύρωσης (Fold 1) μοντέλου GIN για το dataset ENZYMES με Step Decay. Αριστερά: Ακρίβεια (Accuracy), Δεξιά: Απώλεια (Loss). Παρατηρείται σημαντικό χάσμα γενίκευσης (overfitting) για αυτό και εφαρμόστηκε model restoration από την εποχή 140.

Η εκπαίδευση διήρκεσε αυστηρά για  $T_{max} = 350$  εποχές, με επαναφορά του καλύτερου μοντέλου όπως ορίστηκε παραπάνω. Η ομαλή μεταβολή του learning rate κατά την διάρκεια του training αύξησε την ακρίβεια τουλάχιστον κατά 5%.

#### Μ. Μετρικές Αξιολόγησης

Λόγω του περιορισμένου μεγέθους των συνόλων δεδομένων (ιδίως των ENZYMES), δεν χρησιμοποιήθηκε ξεχωριστό σύνολο ελέγχου (test set), καθώς αυτό θα περιόριζε δραστικά τα διαθέσιμα δεδομένα για την εκπαίδευση. Αντ' αυτού, επιλέξαμε το καθιερωμένο τρόπο αξιολόγησης για τα TUDatasets [5], [7], με την μέθοδο Stratified 10-Fold Cross-Validation. Συγκεκριμένα:

- Το σύνολο δεδομένων χωρίστηκε τυχαία σε 10 ισομερή τμήματα (folds), διατηρώντας την αναλογία των κλάσεων (stratified).
- Η διαδικασία εκπαίδευσης επαναλήφθηκε 10 φορές. Σε κάθε επανάληψη, 9 τμήματα χρησιμοποιήθηκαν για εκπαίδευση (training) και 1 τμήμα για επικύρωση (validation).
- Ως τελική επίδοση του μοντέλου αναφέρεται η Μέση Ακρίβεια Επικύρωσης (Mean Validation Accuracy) και η τυπική απόκλιση (Standard Deviation) μεταξύ των 10 folds.
- Ομοίως, και το clustering και το stability analysis εκτελέστηκαν σε κάθε fold και ως αποτελέσματα ορίστηκαν οι μέσοι όροι με την τυπική απόκλιση.

#### Ν. Επίδοση στην Ταξινόμηση

Στον παρακάτω πίνακα **XI** καταγράφεται η ακρίβεια ταξινόμησης (Classification Accuracy %), όπως περιγράφηκε προηγουμένως. Γενικά παρατηρούμε ότι σε όλα τα datasets η ακρίβεια ξεπερνάει κατά πολύ την τυχαία επιλογή, ενώ για τα 10folds της εκπαίδευσης έχουμε αρκετά μικρή διακύμανση (std) που υποδηλώνει σταθερότητα.

Συγκεκριμένα:

- 1) **REDDIT-12K:** Με την στρατηγική step decay με early stopping, η απόλυτη ακρίβεια έφτασε 47.33%, που, ενώ φαίνεται χαμηλή, πρέπει να ληφθεί υπόψη ότι πρόκειται για dataset 11 κλάσεων με τυχαία επιλογή  $\approx 9\%$ . Το υψηλό AUC (0.87) υποδεικνύει ότι το μοντέλο τοποθετεί τη σωστή κλάση με υψηλή πιθανότητα, ακόμα κι αν τελικά δεν την επιλέγει πάντα.
- 2) **IMDB-MULTI:** Παρατηρείται ακρίβεια 51.27% (ανώτερη της τυχαίας για 3 κλάσεις), αλλά το AUC παραμένει στο 0.50. Αυτό το φαινόμενο οφείλεται στην απουσία χαρακτηριστικών κόμβων και στην υψηλή πυκνότητα των γράφων, που καθιστά δύσκολο για το GIN να διακρίνει τις κλάσεις βασιζόμενο αποκλειστικά στον ισομορφισμό, οδηγώντας το μοντέλο σε αβέβαιες προβλέψεις (uniform probabilities).
- 3) **ENZYMES:** Η ακρίβεια ταξινόμησης (65.17%) είναι σημαντικά υψηλότερη από την τυχαία επιλογή (που θα ήταν  $\approx 16.6\%$  για 6 κλάσεις). Σε αντίθεση με τα κοινωνικά δίκτυα, το ENZYMES περιέχει attributes (δευτεροταγείς δομές πρωτεϊνών), τα οποία το GIN εκμεταλλεύτηκε, και χάρη στον μηχανισμό aggregation που διαθέτει, κατάφερε να πετύχει ικανοποιητικό ποσοστό ακρίβειας.

#### Ο. Επίδραση Διάστασης Embeddings

Επίσης, διερευνήθηκε η επίδραση της διάστασης των διανυσμάτων αναπαράστασης ( $d \in \{16, 32, 64, 128, 256\}$ ) στην απόδοση και το υπολογιστικό κόστος. Το πείραμα εκτελέστηκε σε ένα δείγμα (single fold) για κάθε dataset. Η διάσταση των embeddings ορίζεται από την υπερπαράμετρο hidden\_channels.. Με tuning σε αυτή την παράμετρο προέκυψαν τα εξής αποτελέσματα, όπως φαίνονται στον πίνακα **XII** και την εικόνα 6:

- **ENZYMES:** Η μέγιστη ακρίβεια (59.17%) επιτυγχάνεται με ελάχιστο υπολογιστικό κόστος για την διάσταση 64. Οποιαδήποτε αύξηση

Table XI: Συνολική Απόδοση Μοντέλου GIN

| Dataset    | Accuracy            | F1-Score            | AUC                 |
|------------|---------------------|---------------------|---------------------|
| ENZYMES    | 0.6517 $\pm$ 0.0673 | 0.6478 $\pm$ 0.0721 | 0.8895 $\pm$ 0.0417 |
| IMDB-MULTI | 0.5127 $\pm$ 0.0315 | 0.5006 $\pm$ 0.0374 | 0.5000 $\pm$ 0.0    |
| REDDIT-12K | 0.4733 $\pm$ 0.0162 | 0.4507 $\pm$ 0.0174 | 0.8693 $\pm$ 0.0069 |

της διάστασης ( $d = 128$ ) οδήγησε σε άμεση πτώση της απόδοσης λόγω υπερπροσαρμογής, καθώς το dataset είναι μικρό για να στηρίξει τόσες παραμέτρους.

- **IMDB-MULTI:** Η διάσταση 64 είναι επαρκής, και η μετάβαση στο  $d = 128$  προσφέρει βελτίωση +2% στην ακρίβεια, φτάνοντας το 49.67%. Μεγαλύτερες ή μικρότερες διαστάσεις από αυτές τις δύο ρίχνουν την απόδοση.
- **REDDIT-12K:** Η μεγάλη χωρητικότητα εννόησε το REDDIT, με καλύτερη απόδοση στο  $d = 128$  (47.28%). Ωστόσο, αν πάμε στο  $d = 256$ , αυξάνετε ο χρόνος εκπαίδευσης κατά  $\approx 26\%$  (ξεπερνώντας τα 2000 δευτερόλεπτα) χωρίς να προσφέρει βελτίωση στην ακρίβεια.

Βάσει αυτής της ανάλυσης, επιλέχθηκε η διάσταση  $d = 64$  ως η σταθερή ρύθμιση για όλα τα πειράματα για τα ENZYMES και IMDB-MULTI, καθώς προσφέρει την καλύτερη επιλογή μεταξύ ακρίβειας και υπολογιστικού φόρτου, ενώ για το REDDIT χρησιμοποιήθηκε  $d = 128$ , λόγω του μεγάλου μεγέθους του.

#### P. Μηχανισμός *Jumping Knowledge* (JK)

Οι ερευνητές στο [5], προτείνουν την χρήση `jk = 'cat'`, δηλαδή συνένωση όλων των επιπέδων (*Concat*) για το aggregation των στρωμάτων κατά την διάρκεια της εκπαίδευσης. Παρακάτω, παρατίθενται τα αποτελέσματα πειράματος που πραγματοποιήθηκε στο dataset **ENZYMES** ( $d = 64$ ), συγκρίνοντας τρεις στρατηγικές συνάνθροισης: χρήση μόνο του τελευταίου επιπέδου (*Last*), επιλογή μέγιστης τιμής (*Max*), και *concat*. Τα αποτελέσματα (Πίνακας XIII) επιβεβαιώνουν την ιδέα της έρευνας με το 'Last' να πιάνει 35.8%. Οι **Concat** και **Max** πέτυχαν την καλύτερη ακρίβεια, με πολύ μικρή διαφορά μεταξύ τους, που σημαίνει ότι η λήψη πληροφορίας από όλα τα στρώματα είναι απαραίτητη.

#### Q. Ομαδοποίηση

Στον Πίνακα XIV δίνονται οι τιμές του δείκτη ARI και είναι γενικά χαμηλές για όλα τα σύνολα δεδομένων. Το γεγονός αυτό δεν σημαίνει απουσία πληροφορίας στα embeddings, καθώς η ταξινόμηση πέτυχε ικανοποιητικά σκορ, αλλά ότι ο λανθάνοντας χώρος είναι γεωμετρικά πολύπλοκος.

Τα embeddings χρησιμοποιήθηκαν στην raw μορφή τους, χωρίς εφαρμογή μείωσης διαστάσεων (π.χ. PCA) ή κανονικοποίησης (Scaling). Οι αλγόριθμοι όπως ο K-Means βασίζονται στην Ευκλείδεια απόσταση και υποθέτουν ότι τα clusters είναι γραμμικά

διαχωρίσιμα, κάτι που δεν ισχύει πάντα στις αναπαραστάσεις που παράγονται από GNNs. Οι τιμές κοντά στο μηδέν για το IMDB-MULTI οφείλονται στην απουσία χαρακτηριστικών κόμβων. Τα embeddings βασίζονται αποκλειστικά στη δομική ομοιότητα (ισομορφισμό), και οι αλγόριθμοι ομαδοποίησης φαίνεται πως χρειάζονται παραπάνω πληροφορία για σωστή ομαδοποίηση.

Τέλος παρατίθεται η οπτικοποίηση μέσω t-SNE (Εικόνα 7), όπου φαίνεται πως υπάρχει έντονη επικάλυψη μεταξύ των κλάσεων, γεγονός που καθιστά το clustering δύσκολο.

#### R. Ευστάθεια (*Stability Analysis*)

Στους Πίνακες XV, XVI και XVII παρατίθενται τα αποτελέσματα της μελέτης ευστάθειας του GIN. Στο τέλος κάθε fold, εφαρμόστηκαν σε κάθε dataset μια σειρά perturbations και τα δεδομένα που παράχθηκαν δόθηκαν ως είσοδο στο ήδη εκπαιδευμένο μοντέλο και έδωσε νέα embeddings τα οποία συγκρίθηκαν με τα αρχικά σε accuracy και ομοιότητα (cosine similarity), και πάρθηκε ο μέσος όρος και διακύμανση.

Τα αποτελέσματα επιβεβαίωσαν την σταθερότητα του μοντέλου που υποψιαζόμασταν από την μικρή διακύμανση μεταξύ των folds στα πρώτα πειράματα. Επίσης, μπορούμε να παρατηρήσουμε:

##### a) REDDIT-MULTI-12K (Πίνακας XVII)

Εμφανίζει ευαισθησία στην προσθήκη (Edge Add), με αρνητική επίδραση στην απόδοση. Με 20% προσθήκη θορύβου, η ακρίβεια πέφτει στο **26.94%** (πτώση  $> 20\%$  από το baseline), ενώ η ομοιότητα πέφτει στο 0.85. Αυτό οφείλεται στο γεγονός ότι το REDDIT έχει αρκετά αραιούς γράφους και η τυχαία προσθήκη ακμών δημιουργεί "γέφυρες" μεταξύ άσχετων κόμβων, αλλάζοντας τη δομή των κοινοτήτων. Αντίθετα, η αφαίρεση ακμών (40.01% στο 20% noise) είναι λιγότερο επιζήμια, καθώς η βασική πληροφορία διατηρείται μέσω εναλλακτικών μονοπατιών.

##### b) IMDB-MULTI (Πίνακας XVI)

Η ακρίβεια παραμένει σχεδόν αμετάβλητη ( $\approx 50\% - 51\%$ ) και η ομοιότητα embeddings είναι υψηλή (0.95 - 0.99) παρόλο τον θόρυβο. Αυτό οφείλεται στην υψηλή πυκνότητα των ego-networks, όπου η αφαίρεση ή προσθήκη λίγων ακμών δεν αλλάζει τις ιδιότητες ισομορφισμού που ανιχνεύει το μοντέλο.

##### c) ENZYMES (Πίνακας XV)

Παρατηρούμε μια γραμμική, ομαλή πτώση της ακρίβειας καθώς αυξάνεται ο θόρυβος, χωρίς ακραίες διακυμάνσεις. Η υψηλή ομοιότητα embeddings (0.94 - 0.99) υποδεικνύει ότι το μοντέλο



Table XII: Επίδραση Διάστασης Embeddings GIN ( $d$ ) σε Ακρίβεια και Χρόνο Εκπαίδευσης

| Dim ( $d$ ) | ENZYMES      |          | IMDB-MULTI   |          | REDDIT-12K   |          |
|-------------|--------------|----------|--------------|----------|--------------|----------|
|             | Acc (%)      | Time (s) | Acc (%)      | Time (s) | Acc (%)      | Time (s) |
| 16          | 50.83        | 128.5    | 46.33        | 142.6    | 42.41        | 1550.2   |
| 32          | 54.17        | 126.5    | 47.00        | 142.1    | 44.80        | 1570.5   |
| 64          | <b>59.17</b> | 126.8    | 47.67        | 142.4    | 45.52        | 1590.1   |
| 128         | 47.50        | 128.2    | <b>49.67</b> | 143.8    | <b>47.28</b> | 1595.4   |
| 256         | 56.67        | 131.5    | 45.33        | 145.7    | 46.56        | 2020.8   |




Figure 6: Συσχέτιση Ακρίβειας (Accuracy - Μπλε) και Χρόνου Εκπαίδευσης (Time - Κόκκινο) ως συνάρτηση της διάστασης  $d$  του μοντέλου GIN




Figure 7: Οπτικοποίηση t-SNE των embeddings του GIN στο dataset REDDIT-MULTI-12K. Αριστερά: Πραγματικές Ετικέτες (Ground Truth), όπου παρατηρείται έντονη επικάλυψη των κλάσεων. Κέντρο: Συστάδες K-Means. Δεξιά: Συστάδες Spectral Clustering.

Table XIII: Σύγκριση Στρατηγικών Jumping Knowledge (Val Accuracy) του μοντέλου GIN

| JK Mode | Περιγραφή         | Accuracy (%) |
|---------|-------------------|--------------|
| Last    | Final Layer Only  | 35.8         |
| Concat  | Concatenation [5] | <b>54.2</b>  |
| Max     | Element-wise Max  | <b>56.7</b>  |

Table XIV: Clustering Scores μοντέλου GIN

| Dataset    | K-Means             | Spectral            |
|------------|---------------------|---------------------|
| ENZYMES    | $0.0879 \pm 0.0511$ | $0.1585 \pm 0.0721$ |
| IMDB-MULTI | $0.0016 \pm 0.0046$ | $0.0097 \pm 0.0123$ |
| REDDIT-12K | $0.1318 \pm 0.0126$ | $0.1080 \pm 0.0157$ |

βασίζεται σε μεγάλο βαθμό στα χαρακτηριστικά των κόμβων (node attributes), τα οποία παραμένουν αμετάβλητα κατά τη διάρκεια της δομικής διατάραξης, προσδίδοντας robustness στο δίκτυο. Στην περίπτωση που έγιναν shuffle attributes διατηρήθηκαν τα υψηλά ποσοστά ομοιότητας, με το acc να πέφτει ομαλά, που

Table XV: Ανάλυση Ευστάθειας: ENZYMES

| Perturbation  | Ratio (%) | GIN Performance (Mean $\pm$ Std) |                     |
|---------------|-----------|----------------------------------|---------------------|
|               |           | Cosine Sim.                      | Accuracy            |
| Edge Add      | 5%        | 0.99                             | $0.6367 \pm 0.0769$ |
|               | 10%       | 0.98                             | $0.6200 \pm 0.0602$ |
|               | 15%       | 0.96                             | $0.5633 \pm 0.0878$ |
|               | 20%       | 0.95                             | $0.5650 \pm 0.0776$ |
| Edge Remove   | 5%        | 0.99                             | $0.6300 \pm 0.0618$ |
|               | 10%       | 0.98                             | $0.6250 \pm 0.0755$ |
|               | 15%       | 0.97                             | $0.6167 \pm 0.0609$ |
|               | 20%       | 0.94                             | $0.5850 \pm 0.0855$ |
| Shuffle Attr. | 5%        | 0.99                             | $0.6667 \pm 0.0561$ |
|               | 10%       | 0.99                             | $0.6383 \pm 0.0550$ |
|               | 15%       | 0.98                             | $0.6367 \pm 0.0443$ |
|               | 20%       | 0.97                             | $0.6217 \pm 0.0604$ |

δείχνει ότι ακόμα και αν ανακατευτούν τα χαρακτηριστικά, το μοντέλο διατηρεί την πληροφορία από την δομή.

Συμπερασματικά, το GIN παράγει ιδιαίτερα στα-

Table XVI: Ανάλυση Ευστάθειας GIN: IMDB-MULTI

| Perturbation | Ratio (%) | GIN Performance |                     |
|--------------|-----------|-----------------|---------------------|
|              |           | Cosine Sim.     | Accuracy            |
| Edge Add     | 5%        | 0.99            | 0.5140 $\pm$ 0.0324 |
|              | 10%       | 0.99            | 0.5160 $\pm$ 0.0290 |
|              | 15%       | 0.98            | 0.5100 $\pm$ 0.0368 |
|              | 20%       | 0.98            | 0.5060 $\pm$ 0.0426 |
| Edge Remove  | 5%        | 0.99            | 0.5127 $\pm$ 0.0236 |
|              | 10%       | 0.99            | 0.5100 $\pm$ 0.0184 |
|              | 15%       | 0.98            | 0.5180 $\pm$ 0.0270 |
|              | 20%       | 0.95            | 0.5060 $\pm$ 0.0297 |

Table XVII: Ανάλυση Ευστάθειας GIN: REDDIT-MULTI-12K

| Perturbation | Ratio (%) | GIN Performance |                     |
|--------------|-----------|-----------------|---------------------|
|              |           | Cosine Sim.     | Accuracy            |
| Edge Add     | 5%        | 0.97            | 0.4348 $\pm$ 0.0254 |
|              | 10%       | 0.93            | 0.3651 $\pm$ 0.0300 |
|              | 15%       | 0.89            | 0.3076 $\pm$ 0.0295 |
|              | 20%       | 0.85            | 0.2694 $\pm$ 0.0291 |
| Edge Remove  | 5%        | 0.99            | 0.4699 $\pm$ 0.0150 |
|              | 10%       | 0.98            | 0.4487 $\pm$ 0.0251 |
|              | 15%       | 0.97            | 0.4255 $\pm$ 0.0332 |
|              | 20%       | 0.95            | 0.4001 $\pm$ 0.0392 |

θερά embeddings σε πυκνούς γράφους (IMDB) και σε γράφους με χαρακτηριστικά (ENZYMES), αλλά εμφανίζει σημαντική ευαισθησία στην εισαγωγή θορύβου (Add Edges) σε αραιούς γράφους με κοινοτική δομή (REDDIT).

#### S. Ανάλυση Υπολογιστικού Κόστους

Η εκπαίδευση πραγματοποιήθηκε σε περιβάλλον με GPU. Για την ακριβή αποτίμηση των πόρων, καταγράφηκε τόσο ο χρόνος εκτέλεσης όσο και η δέσμευση μνήμης συστήματος (System RAM usage) μέσω της βιβλιοθήκης psutil. Η μνήμη που καταγράφηκε αποτελεί την συνολική μνήμη που δεσμεύτηκε καθόλη την διάρκεια, συμπεριλαμβανομένων βιβλιοθηκών, dataset και λοιπών αρχείων.

Στον Πίνακα XVIII παρουσιάζονται τα αποτελέσματα.

Table XVIII: Υπολογιστικοί Πόροι μοντέλου GIN

| Dataset    | Train Time (s)       | Gen Time (s)     | RAM (MB)         |
|------------|----------------------|------------------|------------------|
| ENZYMES    | 134.62 $\pm$ 1.65    | 0.24 $\pm$ 0.05  | $\approx$ 1606.8 |
| IMDB-MULTI | 348.22 $\pm$ 3.37    | 0.72 $\pm$ 0.15  | $\approx$ 1499.1 |
| REDDIT-12K | 1428.69 $\pm$ 311.58 | 17.05 $\pm$ 0.40 | $\approx$ 4154.2 |

Σχολιασμός:

- 1) Κλιμάκωση Χρόνου Εκτέλεσης (**Scalability**): Στα πιο μικρά datasets (ENZYMES, IMDB-MULTI), η εκπαίδευση ολοκληρώνεται σε λίγα λεπτά ( $\approx$  2 έως 6 λεπτά). Αντιθέτως, στο **REDDIT-12K**, ο χρόνος αυξάνεται στα  $\approx$

24 λεπτά (1428s). Η υψηλή τυπική απόκλιση ( $\pm$ 311s) στο Reddit υποδηλώνει ότι ο μηχανισμός *Early Stopping* ενεργοποιείται σε διαφορετικές χρονικές στιγμές ανά fold, ανάλογα με τη δυσκολία σύγκλισης του εκάστοτε υποσυνόλου δεδομένων.

- 2) Απαιτήσεις Μνήμης (**System RAM**): Η κατανάλωση μνήμης RAM ακολουθεί αυξητική τάση ανάλογα με τον όγκο των δεδομένων. Ενώ τα ENZYMES και IMDB-MULTI απαιτούν  $\approx$  1.5 – 1.6 GB (κυρίως για τη φόρτωση των βιβλιοθηκών και του CUDA runtime), το REDDIT-12K απαιτεί  $\approx$  4.15 GB. Η τιμή αυτή, αν και τριπλάσια, παραμένει διαχειρίσιμη από σύγχρονα συστήματα (ακόμα και σε δωρεάν instances του Colab), επιβεβαιώνοντας ότι η υλοποίηση είναι αποδοτική στο κομμάτι των πόρων.

Table XIX: Σύγκριση Ακρίβειας (Mean Accuracy): Internal GIN vs. External Classifiers


| Dataset    | End-to-End  | Fixed Embeddings (External) |             |      |      |
|------------|-------------|-----------------------------|-------------|------|------|
|            | GIN (Int)   | SVM-L                       | SVM-R       | RF   | MLP  |
| ENZYMES    | <b>0.70</b> | 0.60                        | 0.66        | 0.66 | 0.67 |
| IMDB-MULTI | <b>0.51</b> | 0.40                        | 0.38        | 0.49 | 0.43 |
| REDDIT-12K | 0.47        | 0.47                        | <b>0.48</b> | 0.47 | 0.46 |

#### T. Αξιολόγηση Ποιότητας Embeddings με Εξωτερικούς Ταξινομητές


Πέρα από την end-to-end εκπαίδευση, αξιολογήθηκε η ποιότητα των embeddings του GIN, χρησιμοποιώντας τα ως χαρακτηριστικά εισόδου σε κλασσικούς ταξινομητές. Συγκεκριμένα, τα embeddings του τελευταίου επιπέδου, μετά το sum pooling, αποθηκεύτηκαν και χρησιμοποιήθηκαν για την εκπαίδευση τριών εξωτερικών ταξινομητών:

- **SVM (Linear και RBF kernel)**: Για έλεγχο γραμμικής διαχωρισιμότητας.
- **Random Forest**: Ως μέθοδος συνόλου (ensemble) ανθεκτική στον θόρυβο.
- **MLP (External)**: Ένα ξεχωριστό πολυστρωματικό perceptron.


Στον Πίνακα XIX παρουσιάζεται η Μέση Ακρίβεια (Mean Accuracy) για κάθε μέθοδο. Στα datasets ENZYMES και IMDB-MULTI, το εσωτερικό μοντέλο **Internal GIN** υπερτερεί ξεκάθαρα, επιτυγχάνοντας ακρίβεια 0.70 και 0.51 αντίστοιχα. Στο dataset REDDIT-12K παρατηρείται μια ισοδυναμία επιδόσεων, με το **SVM (RBF)** να σημειώνει οριακά υψηλότερη επίδοση (0.48) έναντι του **Internal GIN** (0.47). Σε όλα τα πειράματα, το Linear SVM εμφανίζει τη χαμηλότερη απόδοση (0.60 στο ENZYMES, 0.40 στο IMDB). Ενώ οι αλγόριθμοι που διαχειρίζονται μη-γραμμικότητες, όπως το Random Forest και το MLP, πλησιάζουν περισσότερο την επίδοση του GIN. Αυτό επιβεβαιώνει την μη-γραμμικότητα και πολυπλοκότητα των embeddings.




(a) ENZYMES (Cosine Similarity)



(b) IMDB (Cosine Similarity)



(c) ENZYMES (Accuracy)



(d) IMDB (Accuracy)

Figure 8: Συγκριτική ανάλυση ευρωστίας (Robustness Analysis) του μοντέλου GIN. Η επάνω σειρά (a, b) απεικονίζει τη Συνημιτονική Ομοιότητα (Cosine Similarity) των embeddings, ενώ η κάτω σειρά (c, d) δείχνει την Ακρίβεια (Accuracy) του μοντέλου υπό καθεστώς δομικού θορύβου.

## IX. GRAPH2VEC

### A. Επισκόπηση

Στόχος του Graph2Vec (G2V) είναι να μάθει για κάθε γράφο  $g$  ένα συμπαγές embedding  $z_g \in \mathbb{R}^d$ , που κωδικοποιεί το περιεχόμενο των Weisfeiler–Lehman (WL) χαρακτηριστικών του.

Θεωρούμε ότι κάθε γράφος ξεκινάει ως ένα Bag-of-Words (BoW) των WL χαρακτηριστικών του και των counts τους:

$$\begin{aligned} g_1 &\rightarrow [\text{count of } f_0, \text{ count of } f_1, \dots, \text{ count of } f \\ g_2 &\rightarrow [\text{count of } f_0, \text{ count of } f_1, \dots, \text{ count of } f \\ &\vdots \\ g_k &\rightarrow [\text{count of } f_0, \text{ count of } f_1, \dots, \text{ count of } f \end{aligned}$$

Το τελικό embedding  $z_{g_i}$  πρέπει να διατηρεί όσο το δυνατόν περισσότερη πληροφορία από το αρχικό διάνυσμα χαρακτηριστικών, σε χαμηλότερη διάσταση και με καλύτερη ομαδοποίηση (clustering) μεταξύ των γράφων.

Το Graph2Vec εκπαιδεύεται με λογική Doc2Vec/Word2Vec: κάθε γράφος είναι “document” και κάθε WL χαρακτηριστικό είναι “word”.

Σε κάθε βήμα SGD επιλέγεται ένα θετικό ζεύγος γράφου–χαρακτηριστικού  $(g, f)$ . Για το ζεύγος αυτό δειγματοληπτούμε  $K$  αρνητικά χαρακτηριστικά  $f_1^-, \dots, f_K^-$ , τα οποία δεν εμφανίζονται στον γράφο  $g$ . Η ποσότητα που θέλουμε να μεγιστοποιήσουμε είναι:

$$\log \sigma(z_g^\top u_f) + \sum_{k=1}^K \log \sigma(-z_g^\top u_{f_k^-}).$$

Μία εποχή αντιστοιχεί σε πλήρες πέρασμα από όλα τα θετικά graph–feature pairs.



### C. Experimental Analysis

#### B. Επέκταση g2v-c (count-aware)

Η αναπαράσταση BoW του Graph2Vec διατηρεί *counts*, όμως το κλασικό skip-gram loss δίνει έμφαση κυρίως στην παρουσία χαρακτηριστικού, όχι επαρκώς στη συχνότητά του.

Παράδειγμα: αν  $c(f, g_1) = 100$  και  $c(f, g_2) = 1$ , και τα δύο παράγουν το ίδιο positive pair.  $f$ . Άρα ο αλγόριθμος κωδικοποιεί κυρίως ότι το  $f$  υπάρχει, χωρίς επαρκή διάκριση μεγάλης έναντι μικρής συχνότητας.

##### a) Βασική ιδέα

Αντί να κατασκευάσουμε token embeddings απο το σύνολο των unique tokens, κατασκευάζουμε embedding απο το σύνολο των unique (feature, count).

##### b) Έλεγχος μεγέθους λεξιλογίου

Για να αποφύγουμε εκρηκτική αύξηση token embeddings, στην πράξη ποσοτικοποιούμε τα counts σε bins:

$$b = \text{bin}(c) \in \{1, \dots, B\}, \quad t = (f, b).$$

##### c) Υλοποίηση

Στην εργασία μας πειραματιστήκαμε με δυο τρόπους παραγωγής των positive pairs απο τα ζεύγη  $(f, c)$ .

##### 1. g2v-c unique (strict ποσότητα):

$$P_{g,f} = \{\text{id}(f, c)\}.$$

##### 2. g2v-c thermo (cumulative thresholds):

$$P_{g,f} = \{\text{id}(f, 1), \dots, \text{id}(f, c)\}.$$

Στο thermo, γράφοι με παρόμοια counts μοιράζονται μέρος των ενεργοποιημένων context tokens. Αυτό στοχεύει στον καλύτερο διαμοιρασμό των positive pairs μεταξύ των γράφων.

Το Graph2Vec είναι άμεσα συνδεδεμένο με τον αλγόριθμο Weisfeiler–Lehman (WL) subtree decomposition.

Στην πράξη όμως τα WL features όταν χρησιμοποιούνται ως features σε graph classification έχουν πολύ μικρό διαμοιρασμό μεταξύ των γράφων. Πολλά features εμφανίζονται σε έναν ή δύο γράφους και συνεισφέρουν ελάχιστο meaningful **training signal**.

Για τον λόγο αυτό, κάνουμε **prune** τα WL features βάσει του document frequency. Αυτό οδηγεί σε μεγάλη μείωση του λεξιλογίου ενώ διατηρεί (και μερικές φορές βελτιώνει) το training signal.

Για παράδειγμα, στο ENZYMES, αφαιρώντας features που εμφανίζονται μόνο σε ένα γράφο μειώνουμε τα tokens κατά 74.4% και ο αλγόριθμος g2v επικεντρώνεται στην εκμάθηση των token που αναγκαστικά παρουσιάζουν διαμοιρασμό μεταξύ των γράφων.

Οι τιμές που χρησιμοποιήσαμε για τα πειράματα μας προέκυψαν ως εξής:

|                     | ENZYMES | IMDB  | REDDIT |
|---------------------|---------|-------|--------|
| # graphs ( $N$ )    | 600     | 1,500 | 11,929 |
| # classes           | 6       | 3     | 11     |
| WL iterations       | 1 and 2 | 2     | 2      |
| Embed dim ( $D$ )   | 128     | 128   | 64     |
| Neg samples ( $K$ ) | 20      | 20    | 15     |
| Initial LR          | 0.05    | 0.1   | 0.1    |
| Epochs              | 300     | 200   | 300    |
| Drop freq           | 1       | 1     | 5      |

Table XX: Dataset Setup

Πολυ σημαντική είναι επίσης η δομή του **training signal**. Παρακάτω συνοψίζουμε τη συμπεριφορά του λεξιλογίου ( $V_{\text{ctx}}$ ) και της πυκνότητας των θετικών ζευγών ( $\mu(P_i)$ ) ανά dataset:

#### ENZYMES

Ο g2v vanilla αλγόριθμος διατηρεί το μικρότερο λεξιλόγιο (1.8k tokens) και πυκνό σήμα ( $\mu \approx 50$  pairs/graph). Οι count-aware μέθοδοι αυξάνουν το λεξιλόγιο στα 2.6k. Ωστόσο, ενώ το unique μειώνει τα θετικά ζεύγη στο μισό ( $\mu \approx 24.5$ ), το thermo ανακτά σημαντικό μέρος της πληροφο-

φορίας( $\mu \approx 32.8$ ).

### IMDB-MULTI

Παρατηρείται παρόμοια τάση. Το λεξιλόγιο διπλασιάζεται ( $386 \rightarrow 620$  tokens). Το signal density πέφτει δραματικά στο unique ( $11.5 \rightarrow 4.9$ ), υποδεικνύοντας ότι τα strict counts είναι σπάνια. Το thermo το βελτιώνει ( $\mu \approx 6.8$ ).

### REDDIT-MULTI

Το λεξιλόγιο εκτοξεύεται από 14k σε 29k tokens. Εδώ, το thermo επιτυγχάνει signal density ( $\mu \approx 87$ ) πολύ κοντά στο Vanilla (96), ενσωματώνοντας ταυτόχρονα την πληροφορία της ποσότητας χωρίς να "αραιώνει" υπερβολικά το context του γράφου.

### D. Time Analysis

Έστω  $D$  η διάσταση των embedding,  $K$  ο αριθμός των negative samples ανά positive event,  $P_i$  ο αριθμός των θετικών graph-context pairs για τον γράφο  $g_i$ , και  $E$  ο αριθμός των training epochs.

Κάθε **training update** περιλαμβάνει dot products μεταξύ ενός graph embedding και ενός positive context embedding, καθώς και  $K$  negative context embeddings. Ένα single dot product έχει κόστος  $\Theta(D)$ , οπότε έχουμε  $\Theta((K+1)D)$  operations ανά positive event.

Δεδομένου ότι μία **epoch** αποτελεί ένα πλήρες πέρασμα από όλα τα positive events, η χρονική πολυπλοκότητα ανά εποχή είναι:

$$\Theta\left(\sum_i P_i \cdot (K+1) \cdot D\right).$$

Για  $E$  εποχές, το συνολικό training cost γίνεται:

$$\Theta\left(E \cdot \sum_i P_i \cdot (K+1) \cdot D\right).$$

Συνεπώς, οι διαφορές στο **runtime** μεταξύ μεθόδων και datasets οφείλονται κυρίως στις διακυμάνσεις του συνολικού αριθμού των positive events  $\sum_i P_i$ , καθώς και στις επιλεγμένες τιμές των  $K$  και  $D$ .

| ENZYMES Runtime |         |       |             |
|-----------------|---------|-------|-------------|
| Method          | ms/step | ms/ep | total (min) |
| g2v vanilla     | 1.30    | 803   | 4.03        |
| g2v-c unique    | 0.80    | 493   | 2.47        |
| g2v-c thermo    | 0.90    | 552   | 2.76        |

| IMDB-MULTI Runtime |         |       |             |
|--------------------|---------|-------|-------------|
| Method             | ms/step | ms/ep | total (min) |
| g2v vanilla        | 0.05    | 804   | 2.68        |
| g2v-c unique       | 0.10    | 745   | 2.48        |
| g2v-c thermo       | 0.08    | 787   | 2.62        |

Table XXII: Χρόνοι εκτέλεσης (IMDB)

| Reddit-12K Runtime |         |       |             |
|--------------------|---------|-------|-------------|
| Method             | ms/step | ms/ep | total (min) |
| g2v vanilla        | 0.90    | 10.5k | 52.3        |
| g2v-c unique       | 0.80    | 9.6k  | 48.2        |
| g2v-c thermo       | 0.90    | 10.3k | 51.4        |

Table XXIII: Χρόνοι εκτέλεσης (Reddit)

### E. Memory Analysis

#### Graph embeddings

Αποθηκεύονται ως `float32` dense matrix ( $N \times D$ ). Για g2v vanilla / unique / thermo έχουμε:

- 300 / 300 / 300 KiB στο ENZYMES
- 375 / 375 / 375 KiB στο IMDB
- 2.91 / 2.91 / 2.91 MiB στο REDDIT

#### Context embeddings

Αποθηκεύονται ως `float32` dense matrix ( $V_{\text{ctx}} \times D$ ). Για g2v vanilla / unique / thermo έχουμε:

- 929 KiB / 1.28 MiB / 1.28 MiB στο ENZ.
- 97 / 155 / 155 KiB στο IMDB
- 3.53 / 7.24 / 7.24 MiB στο REDDIT

#### Stored positives index

Αποθηκεύεται ως `int64` 1-D array μήκους  $\sum_i P_i$ . Για g2v vanilla / unique / thermo έχουμε:

- 236 / 115 / 154 KiB στο ENZYMES
- 134 / 58 / 80 KiB στο IMDB
- 8.72 / 6.81 / 7.92 MiB στο REDDIT

#### Total persistent memory

Το άθροισμα όλων των components που διατηρούνται μόνιμα στη VRAM/RAM.

| Dataset | Vanilla  | Unique   | Thermo   |
|---------|----------|----------|----------|
| ENZYMES | 1.44 MiB | 1.71 MiB | 1.74 MiB |
| IMDB    | 0.60 MiB | 0.58 MiB | 0.60 MiB |
| REDDIT  | 15.2 MiB | 17.0 MiB | 18.1 MiB |

Table XXIV: Total Persistent Memory

### F. Evaluation

#### 1) Πρωτόκολλο

Χρησιμοποιούμε research-grade cross-validation: 10 splits  $\times$  3 repeats = 30 folds. **Metrics:** macro-F1, accuracy, AUC (όπου υποστηρίζεται). **Models:** Linear SVM (LinSVC), RBF SVM (RBF), kNN, Random Forest (RF), MLP.

#### 2) Αποτελέσματα (ENZYMES)

| Classification Results |        |             |             |      |
|------------------------|--------|-------------|-------------|------|
| Method                 | CLS    | Acc         | F1          | AUC  |
| g2v-c thermo           | LinSVC | 0.52        | 0.52        | -    |
|                        | RBF    | <b>0.70</b> | <b>0.70</b> | -    |
|                        | KNN    | 0.65        | 0.65        | 0.84 |
|                        | RF     | 0.64        | 0.63        | 0.88 |
|                        | MLP    | 0.62        | 0.61        | 0.86 |
| g2v-c unique           | LinSVC | 0.43        | 0.42        | -    |
|                        | RBF    | 0.64        | 0.63        | -    |
|                        | KNN    | 0.56        | 0.55        | 0.83 |
|                        | RF     | 0.59        | 0.58        | 0.86 |
|                        | MLP    | 0.56        | 0.56        | 0.82 |
| g2v vanilla            | LinSVC | 0.52        | 0.51        | -    |
|                        | RBF    | 0.68        | 0.68        | -    |
|                        | KNN    | 0.63        | 0.63        | 0.86 |
|                        | RF     | 0.64        | 0.64        | 0.88 |
|                        | MLP    | 0.56        | 0.55        | 0.84 |

| Clustering Quality (ARI, Sil) |              |              |
|-------------------------------|--------------|--------------|
| Method                        | KMeans       | Spectral     |
| Thermo                        | 0.029, 0.039 | 0.012, 0.022 |
| Unique                        | 0.030, 0.036 | 0.033, 0.020 |
| Vanilla                       | 0.025, 0.048 | 0.014, 0.036 |

Table XXV: Classification and Clustering results on ENZYMES

### 3) Αποτελέσματα (IMDB-MULTI)

| Classification Results |        |             |             |      |
|------------------------|--------|-------------|-------------|------|
| Method                 | CLS    | Acc         | F1          | AUC  |
| g2v-c thermo           | LinSVC | 0.43        | 0.43        | -    |
|                        | RBF    | <b>0.47</b> | <b>0.46</b> | -    |
|                        | KNN    | 0.43        | 0.42        | 0.62 |
|                        | RF     | 0.45        | 0.45        | 0.64 |
|                        | MLP    | 0.40        | 0.39        | 0.58 |
| g2v-c unique           | LinSVC | 0.41        | 0.40        | -    |
|                        | RBF    | 0.46        | 0.45        | -    |
|                        | KNN    | 0.43        | 0.43        | 0.62 |
|                        | RF     | 0.45        | 0.45        | 0.62 |
|                        | MLP    | 0.41        | 0.40        | 0.59 |
| g2v vanilla            | LinSVC | 0.43        | 0.43        | -    |
|                        | RBF    | 0.43        | 0.43        | -    |
|                        | KNN    | 0.44        | 0.44        | 0.62 |
|                        | RF     | 0.46        | 0.45        | 0.64 |
|                        | MLP    | 0.44        | 0.44        | 0.62 |

Clustering Quality (ARI, Sil)

| Method  | KMeans       | Spectral     |
|---------|--------------|--------------|
| Thermo  | 0.007, 0.321 | 0.006, -     |
| Unique  | 0.023, 0.340 | 0.005, 0.114 |
| Vanilla | 0.005, 0.288 | 0.004, 0.249 |

Table XXVI: Classification and Clustering results on IMDB-MULTI

### 4) Αποτελέσματα (REDDIT)

| Classification Results |        |             |      |             |
|------------------------|--------|-------------|------|-------------|
| Method                 | CLS    | Acc         | F1   | AUC         |
| g2v-c thermo           | LinSVC | 0.29        | 0.24 | -           |
|                        | RBF    | 0.32        | 0.31 | -           |
|                        | KNN    | 0.26        | 0.20 | 0.64        |
|                        | RF     | 0.31        | 0.20 | 0.75        |
|                        | MLP    | <b>0.34</b> | 0.29 | <b>0.78</b> |
| g2v-c unique           | LinSVC | 0.29        | 0.25 | -           |
|                        | RBF    | 0.31        | 0.30 | -           |
|                        | KNN    | 0.27        | 0.20 | 0.68        |
|                        | RF     | 0.31        | 0.20 | 0.75        |
|                        | MLP    | 0.32        | 0.27 | 0.77        |
| g2v vanilla            | LinSVC | 0.28        | 0.22 | -           |
|                        | RBF    | 0.31        | 0.29 | -           |
|                        | KNN    | 0.27        | 0.19 | 0.64        |
|                        | RF     | 0.30        | 0.18 | 0.72        |
|                        | MLP    | 0.31        | 0.24 | 0.75        |

Clustering Quality (ARI, Sil)

| Method  | KMeans        | Spectral     |
|---------|---------------|--------------|
| Thermo  | 0.064, 0.014  | 0.010, 0.134 |
| Unique  | 0.054, 0.011  | 0.013, 0.012 |
| Vanilla | 0.061, -0.001 | 0.008, 0.020 |

Table XXVIII: Classification and Clustering results on REDDIT


### G. Stability Analysis

Για να αξιολογήσουμε το robustness των embeddings, εκτελέσαμε perturbation analysis στο ENZYMES dataset.

Αφαιρέσαμε τυχαία ακμές με πιθανότητες  $p \in \{0.05, \dots, 0.5\}$  και ξανα-εκπαideύσαμε τα μοντέλα ( $D = 128$ ). Καταγράφουμε:

- 1) **Stability Score:** Η μέση συνημιτονική ομοιότητα (cosine similarity) μεταξύ του embedding του γράφου  $g$  και της perturbed εκδοχής του  $g'$ .
- 2) **Performance Delta ( $\Delta$  Acc):** Η διαφορά στο classification accuracy συγκριτικά με το unperturbed baseline.

Όλες οι μέθοδοι επιδεικνύουν υψηλό stability (similarity  $> 0.93$ ) ακόμα και με 50% edge removal.



## I. Dimensionality Analysis

Αναλύσαμε την επίδραση της διάστασης embedding  $D$  στο classification accuracy χρησιμοποιώντας το dataset **ENZYMES**. Δοκιμάσαμε  $D \in \{8, 32, 64, 128, 256\}$ .

Παρακάτω απεικονίζουμε τη βελτίωση της απόδοσης ( $\Delta$  Accuracy) σε σχέση με το baseline του  $D = 8$ .

Ενώ όλες οι μέθοδοι έχουν χαμηλή απόδοση σε πολύ μικρές διαστάσεις, συγκλίνουν γρήγορα καθώς το  $D$  αυξάνεται. Η μέθοδος thermo επιτυγχάνει το υψηλότερο peak accuracy (65.1%) στο  $D = 256$ .

Αυτό υποδηλώνει ότι η πλουσιότερη πληροφορία **context** (που παρέχουν τα counts) αξιοποιείται καλύτερα σε latent spaces υψηλότερης διάστασης.




Figure 11: Dimensionality impact on accuracy.

## J. Visualizations

Οπτικοποιούμε τα embeddings για το **REDDIT** dataset χρησιμοποιώντας UMAP και t-SNE. Το παρακάτω grid συγκρίνει το structural separation που επιτυγχάνουν οι διάφορες μέθοδοι context construction. Τα plots βρίσκονται στο Appendix ??, ??, ??.

## X. Συγκριτική Ανάλυση των Μεθόδων

Ακολουθεί η συγκριτική ανάλυση των αποτελεσμάτων των μεθόδων. Ακολουθούμε 10-Fold Stratified Training έχοντας επιλέξει την baseline έκδοση των papers που παρουσιάζουν τις μεθόδους. Για κάθε μέθοδο χρησιμοποιούμε τα αποτελέσματα του μοντέλου στο οποίο αποδίδει καλύτερα.

Για την μέθοδο FGSD χρησιμοποιούμε Random Forest μοντέλο (estimators=500, maxDepth=20) και το configuration Polynomial bins=150, range=4.0 στο dataset ENZYMES, στο IMDB χρησιμοποιούμε Random Forest μοντέλο (estimators=500, maxDepth=20) και polynomial embedding (bins=150, range=3.1 και τέλος για το Reddit το ίδιο RF με harmonic embedding bins=500, range=14.61.

Για το μοντέλο GIN χρησιμοποιήθηκαν οι τιμές validation accuracy όπως προέκυψαν από την 10-fold εκπαίδευση του μοντέλου πάνω σε κάθε dataset.

Για την μέθοδο graph2vec χρησιμοποιούμε rbf svc μοντέλο ( $C = 10$ ,  $\gamma = \text{scale}$ ) και random forest (estimators=200, maxDepth=50) στο dataset ENZYMES, στο χρησιμοποιούμε Random Forest (estimators=200, maxDepth=50) και για το Reddit rbf svm ( $C = 10$ ,  $\gamma = \text{scale}$ ) και mlp (hidden size 128).

### A. Σύγκριση επί των επιδόσεων των μοντέλων

Κάθε μέθοδος αποδίδει συγκεκριμένα προτερήματα στην ταξινόμηση. Οι μέθοδοι G2V και GIN έχουν την δυνατότητα εκπαίδευσης και άρα μεγαλύτερης προσαρμογής στα δεδομένα συγκριτικά με την FGSD. Αυτό φαίνεται χαρακτηριστικά στο dataset enzymes όπου η FGSD αδυνατεί να συλλάβει τα δεδομένα των κόμβων. Αντίθετα, GIN και G2V έχουν παραπλήσιες επιδόσεις.

Στο dataset IMDB, παρατηρούμε πως όλες οι μέθοδοι είναι κοντά με το GIN να έχει ένα +0.05 στο accuracy. Αυτό οφείλεται στην ικανότητά του να πιάνει την τοπολογία των γράφων. Οι κλάσεις των ταινιών καθορίζονται από την τοπολογία ως επί το πλείστον (χλίκες, star-graphs κλπ), το GIN με το sum aggregation διατηρεί αυτή την πληροφορία. Αντίθετα δυσκολεύεται να καταγράψει την πληροφορία απο βαθιές τοπολογίες, αυτό συμβαίνει γιατί τα wl features έχουν μικρό διαμοιρασμό σε μεγάλα itters και η μείωση της συνάρτησης κόστους σε αυτά δεν προκαλεί ομαδοποίηση. Το fgsd έχοντας ως πληροφορία μόνο τις αποστάσεις, δεν μπορεί να ξεχωρίσει τόσο το σχήμα, καθώς διαφορετικά σχήματα ενδέχεται να δίνουν παρόμοιες αποστάσεις.

Τέλος αξίζει να σημειωθεί η δραματική αποτυχία του G2V στο Reddit dataset. Ενώ το FGSD και το GIN πιάνουν την τοπολογία των γράφων του reddit, το οποίο είναι το πιο σημαντικό στοιχείο σε αυτή το Dataset -έναν sparse γράφος είναι πιο πιθανό να βρίσκεται στο politics αντί στο AskReddit-, το G2V έχει πρόβλημα στο scalability. Παρόλο που ο αριθμός των γράφων είναι γραμμικός συντελεστής στην πολυπλοκότητα, η αύξηση του οδηγεί και σε αύξηση



του λεξιλογίου που είναι και αυτός γραμμικός συντελεστής στη πολυπλοκότητα. Για αυτό χρειάστηκε subsampling κατά τη διάρκεια της εκτέλεσης και είχε επίπτωση στην επίδοση του.

Table XXIX: Συγκριτική Αξιολόγηση Μεθόδων στο ENZYMES Dataset

| Μέθοδος              | Accuracy                            | F1-Score                            | AUC                                  |
|----------------------|-------------------------------------|-------------------------------------|--------------------------------------|
| FGSD (Polynomial)    | 0.4632 $\pm$ 0.058                  | 0.4566 $\pm$ 0.059                  | 0.7845**                             |
| Graph2Vec (Vanilla)* | <b>0.6800 <math>\pm</math> 0.03</b> | <b>0.6800 <math>\pm</math> 0.03</b> | 0.8800 $\pm$ 0.02                    |
| GIN (End-to-End)     | 0.6517 $\pm$ 0.067                  | 0.6478 $\pm$ 0.072                  | <b>0.8895 <math>\pm</math> 0.042</b> |

\*Graph2Vec values report best performance (SVM RBF).

\*\*Τιμή από τα metrics της Ενότητας VII.

Table XXX: Συγκριτική Αξιολόγηση Μεθόδων στο IMDB-MULTI Dataset

| Μέθοδος              | Accuracy                             | F1-Score                             | AUC                                 |
|----------------------|--------------------------------------|--------------------------------------|-------------------------------------|
| FGSD (Polynomial)    | 0.4699 $\pm$ 0.040                   | 0.4566 $\pm$ 0.042                   | -                                   |
| Graph2Vec (Vanilla)* | 0.4600 $\pm$ 0.07                    | 0.4500 $\pm$ 0.05                    | <b>0.6400 <math>\pm</math> 0.01</b> |
| GIN (End-to-End)     | <b>0.5127 <math>\pm</math> 0.032</b> | <b>0.5006 <math>\pm</math> 0.037</b> | 0.5000 $\pm$ 0.00                   |

Table XXXI: Συγκριτική Αξιολόγηση Μεθόδων στο REDDIT-MULTI-12K Dataset

| Μέθοδος              | Accuracy                             | F1-Score                             | AUC                                  |
|----------------------|--------------------------------------|--------------------------------------|--------------------------------------|
| FGSD (Harmonic)      | 0.4513 $\pm$ 0.014                   | 0.4305 $\pm$ 0.013                   | 0.8487**                             |
| Graph2Vec (Vanilla)* | 0.3100                               | 0.2900                               | 0.7500                               |
| GIN (End-to-End)     | <b>0.4733 <math>\pm</math> 0.016</b> | <b>0.4507 <math>\pm</math> 0.017</b> | <b>0.8693 <math>\pm</math> 0.007</b> |

\*\*Τιμή από τα metrics της Ενότητας VII.

## B. Συγκριτική ανάλυση χρόνου-acc και χρήσης μνήμης-acc

Η ανάλυση χρόνου-ακρίβειας καταγράφεται στο XXXII. Είναι ξεκάθαρο πως αν θέλουμε άμεσα αποτελέσματα σε μικρούς γράφους και με σχετική αξιοπιστία επιλέγουμε το FGSD, ωστόσο όσο μεγαλώνουν οι γράφοι η μέθοδος χάνει το trade-off καθώς είναι αργή και σε χρόνο και χαμηλά σε ακρίβεια, χωρίς όμως να δεν περιλαμβάνει έξτρα κόστος εκπαίδευσης. Για τις μεθόδους GIN και G2V, συγκρίνουμε τον χρόνο εκπαίδευσης, και σε μεγάλα dataset όπως το REDDIT, το GIN είναι πιο αποδοτικό.

Ακόμα, αν συγκρίνουμε τα generation times των μεθόδων θα δούμε ότι στην μέθοδο G2V και GIN είναι κάτω από ένα δευτερόλεπτο ακόμα και στο Reddit, που το FGSD θα κάνει αρκετά λεπτά. Τέλος πρέπει να σημειωθεί πως το GIN απαιτεί την χρήση κάρτας γραφικών και οι μετρήσεις του G2V και του FGSD είναι σε CPU, όπως φαίνεται στον πίνακα XXXII.

Ως προς την μνήμη, το GIN εφόσον τρέχει σε GPU κάνει allocation στην GPU οπότε δεν έχει νόημα η σύγκριση με τις άλλες δύο μεθόδους. Συγκρίνουμε το G2V με το FGSD ως προς την χρήση μνήμης κατά την εκπαίδευση/παραγωγή των embeddings. Μετράμε τι κάνει allocation η Python.

Για το g2v πολύ σημαντικό στη διαχείριση μνήμης ήταν το feature pruning που κάναμε με βάση το frequency καθώς μείωσε κατά πολύ το vocabulary και

Table XXXII: Σύγκριση Ακρίβειας και Χρόνου (s) και για τις τρεις μεθόδους. Σημειώνεται ότι στο FGSD αναφερόμαστε στον χρόνο παραγωγής των embeddings καθώς δεν γίνεται εκπαίδευση.

| Dataset    | Method | Accuracy                              | Time (s)     |
|------------|--------|---------------------------------------|--------------|
| ENZYMES    | GIN    | 0.6517 $\pm$ 0.0673                   | 134.62       |
|            | G2V    | 0.68                                  | 241.80       |
|            | FGSD   | 0.4632                                | <b>4.41*</b> |
| IMDB-MULTI | GIN    | <b>0.5127 <math>\pm</math> 0.0315</b> | 348.22       |
|            | G2V    | 0.46                                  | 160.80       |
|            | FGSD   | 0.4699                                | <b>6.90*</b> |
| REDDIT-12K | GIN    | <b>0.4733 <math>\pm</math> 0.0162</b> | 1428.69      |
|            | G2V    | 0.31                                  | 3138.00      |
|            | FGSD   | 0.4513                                | 2804.82*     |

\*FGSD time απευθύνεται στον χρόνο παραγωγής των embeddings.

έκανε τη μνήμη πολύ πιο διαχειρίσιμη. Το FGSD έχει σταθερά αύξηση της μνήμης ανάλογα το μέγεθος των embeddings, παρατηρούμε ότι η αύξηση στη χρήση είναι γραμμική σύμφωνα με το μέγεθος των γράφων.

Table XXXIII: Μνήμη vs Απόδοση trade-off: Graph2Vec vs FGSD.

| Dataset    | Method | Accuracy      | RAM (MB)     |
|------------|--------|---------------|--------------|
| ENZYMES    | G2V    | <b>0.6800</b> | 14.44        |
|            | FGSD   | 0.4632        | <b>2.09</b>  |
| IMDB-MULTI | G2V    | 0.4600        | <b>0.60</b>  |
|            | FGSD   | <b>0.4699</b> | 3.99         |
| REDDIT-12K | G2V    | 0.3100        | <b>15.20</b> |
|            | FGSD   | <b>0.4513</b> | 52.33        |

## C. Ανάλυση σταθερότητας

Παρατηρούμε πως οι μέθοδοι με εκπαίδευση (G2V, GIN) είναι πολύ πιο σταθεροί.

Η μέθοδος FGSD όταν χάνει αποστάσεις αλλάζουν σημαντικά οι ιδιοτιμές του Λαπλασιανού πίνακα και άρα είναι ασταθής μέθοδος.

Το GIN επειδή χρησιμοποιεί τα node attributes, παρόλο τον θόρυβο κατάφερε να ξεχωρίσει με επιτυχία τους γράφους, χωρίς επανεκπαίδευση. Φαίνεται πως με το sum aggregation, έχει κατανοήσει σε βάθος το dataset και μπορεί να παράξει σταθερά embeddings.

Το g2v επειδή περνάει πρώτα από το φίλτρο των wl features κατάφερε να διατηρήσει πολύ μεγάλο stability. Αυτό είναι γιατί τα pertributions επηρέαζαν το count των features και το bow του g2v κρατούσε μορφοποιημένη τη πληροφορία.

Τέλος, όσον αναφορά την προσθήκη θορύβου με shuffle attributes, η μέθοδος FGSD δεν λαμβάνει υπ' όψην τα node attributes οπότε ως προς αυτό είναι safe αν και λιγότερο αποδοτική ακόμα και με τα μπερδεμένα attributes από ότι το GIN.

## D. Σύγκριση σε Clustering

Και τα τρία dataset αποδείχθηκαν δύσκολα στην εφαρμογή των αλγορίθμων Kmeans και spectral clus-

Table XXXIV: Συγκριτική Ανάλυση Σταθερότητας: FGSD (Harmonic) vs. GIN vs. G2V στο ENZYMES).

| Perturbation  | Ratio | FGSD (Harmonic Avg) |             | GIN         |              | Graph2Vec   |      |
|---------------|-------|---------------------|-------------|-------------|--------------|-------------|------|
|               |       | Sim                 | Drop        | Sim         | Drop         | Sim         | Drop |
| Edge Add      | 5%    | 0.79                | 8.2%        | <b>0.99</b> | <b>2.3%</b>  | -           | -    |
|               | 10%   | 0.73                | 12.3%       | <b>0.98</b> | <b>4.9%</b>  | -           | -    |
|               | 20%   | 0.59                | 15.8%       | <b>0.95</b> | <b>13.3%</b> | -           | -    |
| Edge Remove   | 5%    | 0.86                | 8.9%        | <b>0.99</b> | <b>3.3%</b>  | 0.97        | -    |
|               | 10%   | 0.81                | 7.5%        | <b>0.98</b> | <b>4.1%</b>  | 0.97        | -    |
|               | 20%   | 0.71                | 14.9%       | 0.94        | <b>10.2%</b> | <b>0.96</b> | -    |
| Shuffle Attr. | 5%    | 1.00                | 0.0%        | 0.99        | <b>-2.3%</b> | -           | -    |
|               | 10%   | <b>1.00</b>         | <b>0.0%</b> | 0.99        | 2.1%         | -           | -    |
|               | 20%   | <b>1.00</b>         | <b>0.0%</b> | 0.97        | 4.6%         | -           | -    |

\*FGSD averages include all datasets. GIN/G2V refer to ENZYMES.

tering καθώς βασίζονται στις αποστάσεις των embeddings στον γεωμετρικό χώρο. Όπως φαίνεται και στα διαγράμματα 12, το ground truth έχει πολλά embeddings επικαλυπτόμενα, και οι κλάσεις μερδεμένες, για να γίνει σωστό clustering. Στα πειραματικά αποτελέσματα, αν και χαμηλά μπορούμε να δούμε πως το GIN έβγαλε το μεγαλύτερο kmeans ARI στο REDDIT (0.1318) γιατί το GIN είναι σχεδιασμένο με βάση το 1-WL test να ξεχωρίζει δομικές διαφορές.

Ο πίνακας αποτελεσμάτων XXXV.

Table XXXV: Σύγκριση Αποτελεσμάτων Ομαδοποίησης (ARI & Silhouette). Για το FGSD επιλέχθηκε το καλύτερο μοντέλο (Harmonic ή Polynomial) και το G2V χρησιμοποιούμε την εκδοχή Vanilla.

| Dataset    | Method | K-Means       |              | Spectral      |              |
|------------|--------|---------------|--------------|---------------|--------------|
|            |        | ARI           | Sil          | ARI           | Sil          |
| ENZYMES    | GIN    | <b>0.0879</b> | -            | <b>0.1585</b> | -            |
|            | G2V    | 0.0250        | 0.048        | 0.0140        | 0.036        |
|            | FGSD   | 0.0292        | <b>0.295</b> | 0.0432        | <b>0.163</b> |
| IMDB-MULTI | GIN    | 0.0016        | -            | 0.0097        | -            |
|            | G2V    | 0.0050        | 0.288        | 0.0040        | 0.249        |
|            | FGSD   | <b>0.0062</b> | <b>0.328</b> | <b>0.0141</b> | <b>0.302</b> |
| REDDIT-12K | GIN    | <b>0.1318</b> | -            | <b>0.1080</b> | -            |
|            | G2V    | 0.0610        | -0.001       | 0.0080        | 0.020        |
|            | FGSD   | 0.0878        | <b>0.134</b> | 0.0766        | <b>0.128</b> |

## XI. Συμπεράσματα

Στην παρούσα εργασία πραγματοποιήθηκε συγκριτική αξιολόγηση μεθόδων graph embedding σε σύνολα δεδομένων διαφορετικής κλίμακας. Τα αποτελέσματα αναδεικνύουν τα πλεονεκτήματα και τα μειονεκτήματα κάθε προσέγγισης, προσφέροντας χρήσιμες κατευθυντήριες γραμμές για την επιλογή κατάλληλων μεθόδων αναλόγως τα διαθέσιμα trade-offs που μπορούμε να ανεχθούμε. Οι μέθοδοι με χρήση νευρωνικών δικτύων και εν γένει εκπαίδευσης είναι πιο προσαρμοστικές και σταθερές από εκείνες στο χώρο του φάσματος.

Συγκεκριμένα το μοντέλο GIN μεγιστοποιεί την εκφραστική του ικανότητα με τη χρήση injective sum aggregation και προσεγγίζει την ακρίβεια του τεστ ισομορφισμού (1-WL). Αυτό το κάνει αρκετά αποδοτικό σε tasks ταξινόμησης, καθώς καταφέρνει να μάθει και να ξεχωρίζει γράφους από την δομή

τους. Από την πειραματική αξιολόγηση φάνηκε ότι το GIN μπορεί να πετύχει ανταγωνιστικές επιδόσεις ακρίβεια και σταθερότητα. Συνολικά αποτελεί μια αποδοτική και εκφραστική αρχιτεκτονική GNN για ανάλυση δεδομένων σε μορφή γράφων.

Η μέθοδος FGSD αδυνατεί να κατανοήσει σύνθετες τοπολογίες, ενώ ταυτόχρονα ο αλγόριθμος δεν έχει ωριμάσει στην κοινότητα. Η μόνη διαθέσιμη Open Source υλοποίηση δεν είναι αποδοτική. Πιστεύουμε πως με την μέθοδο Chebyshev σε υλοποίηση τύπου NumPy, η μέθοδος FGSD μπορεί να είναι μία energy efficient επιλογή λόγω ταχύτητας σε μικρά datasets και σε μεγαλύτερα λόγω της απουσίας εκπαίδευσης. Επίσης, εκλείπεται σε λειτουργικό standard pipeline το οποίο θα επιτρέψει συστηματική και αποδοτική έρευνα πάνω στην μέθοδο. Στην παρούσα εργασία έγιναν βήματα προς αυτή την κατεύθυνση με μια πρώτη υλοποίηση της προσέγγισης Chebyshev και με το pipeline της προ-ανάλυσης.

Συνολικά, τα πειράματα δείχνουν ότι το Graph2Vec αποτελεί αποτελεσματικό unsupervised πλαίσιο για εκμάθηση graph embeddings, αλλά η ποιότητα του training signal εξαρτάται έντονα από τον τρόπο κατασκευής του context.

Η vanilla εκδοχή κωδικοποιεί κυρίως την παρουσία των WL χαρακτηριστικών, ενώ οι count-aware παραλλαγές που φτιαξαμε προσπαθούν να εισάγουν πληροφορία συχνότητας. Από αυτές, η **g2v-c unique** είναι πιο αυστηρή και συχνά αραιώνει υπερβολικά το signal (λιγότερα positive pairs), με αποτέλεσμα μικρότερη ή ασυνεπή βελτίωση. Αντίθετα, η **g2v-c thermo** διατηρεί καλύτερο διαμοιρασμό context μεταξύ γράφων αλλά δεν υπάρχει επαρκής διαφοροποίηση από τη vanilla μέθοδο. Τέλος, αξίζει να σημειωθεί η πολύ καλή απόδοση του αλγορίθμου σε perturbations καθώς και ότι το **pruning** των WL features με χαμηλό document frequency απόδειχθηκε κρίσιμο καθώς μειώνει σημαντικά το λεξιλόγιο χωρίς απώλεια, και συχνά με βελτίωση, του χρήσιμου learning signal.

## XII. FUTURE WORK

- Υλοποίηση σε C της προσέγγισης Chebyshev με Python C Extension και Python Wrapper.
- Grid Search για την ευρετική συνάρτηση της προ-ανάλυσης της μεθόδου FGSD.
- Self-Supervised Pre-training του μοντέλου GIN.
- Περαιτέρω διερεύνηση επεκτάσεων του αλγορίθμου G2V.

## REFERENCES

- [1] S. Verma and Z.-L. Zhang, "Hunt for the unique, stable, sparse and fast feature learning on graphs," in *Proceedings of the 31st Conference on Neural Information Processing Systems (NeurIPS)*, Long Beach, CA, USA, 2017.
- [2] A. Narayanan, M. Chandramohan, P. Venkatesan, L. Chen, Y. Liu, and S. Jaiswal, "Graph2Vec: Learning distributed representations of graphs," in *Proceedings of the 13th International Workshop on Mining and Learning with Graphs (MLG)*, ACM, 2015.
- [3] <https://github.com/benedekrozemberczki/karateclub>

- [4] B. Rozemberczki, O. Kiss, R. Sarkar, "Karate Club: An API Oriented Open-source Python Framework for Unsupervised Learning on Graphs," in *Proceedings of the 29th ACM International Conference on Information and Knowledge Management (CIKM '20)*
- [5] K. Xu, W. Hu, J. Leskovec, and S. Jegelka, "How powerful are graph neural networks?" in *Proceedings of the International Conference on Learning Representations (ICLR)*, New Orleans, LA, USA, 2019.
- [6] M. Fey and J. E. Lenssen, "Fast graph representation learning with PyTorch Geometric," in *ICLR Workshop on Representation Learning on Graphs and Manifolds*, New Orleans, LA, USA, 2019.
- [7] C. Morris, N. M. Kriege, F. Bause, K. Kersting, P. Mutzel, and M. Neumann, "TUDataset: A collection of benchmark datasets for learning with graphs," in *ICML 2020 Workshop on Graph Representation Learning and Beyond*, Vienna, Austria, 2020.
- [8] T. N. Kipf and M. Welling, "Semi-Supervised Classification with Graph Convolutional Networks," in *International Conference on Learning Representations (ICLR)*, 2017.
- [9] W. L. Hamilton, Z. Ying, and J. Leskovec, "Inductive Representation Learning on Large Graphs," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [10] B. Weisfeiler and A. Lehman, "A reduction of a graph to a canonical form and an algebra arising during this reduction," in *Nauchno-Tekhnicheskaya Informatsia*, vol. 2, no. 9, 1968.

## APPENDIX A

### Πρόσθετα Αποτελέσματα και Οπτικοποιήσεις



Figure 12: ENZYMES DATASET, Harmonic, t-SNE, UMAP




Figure 13: IMDB DATASET, Harmonic, t-SNE, UMAP




Figure 14: REDDIT DATASET, Polynomial, t-SNE, UMAP




Figure 15: UMAP Visualizations Comparison




Figure 16: T-SNE Visualizations Comparison